1장. 인공지능 및 데이터사이언스 개론

INDEX

인공지능 역사

인공지능 연구분야

지도학습

비지도학습

강화학습

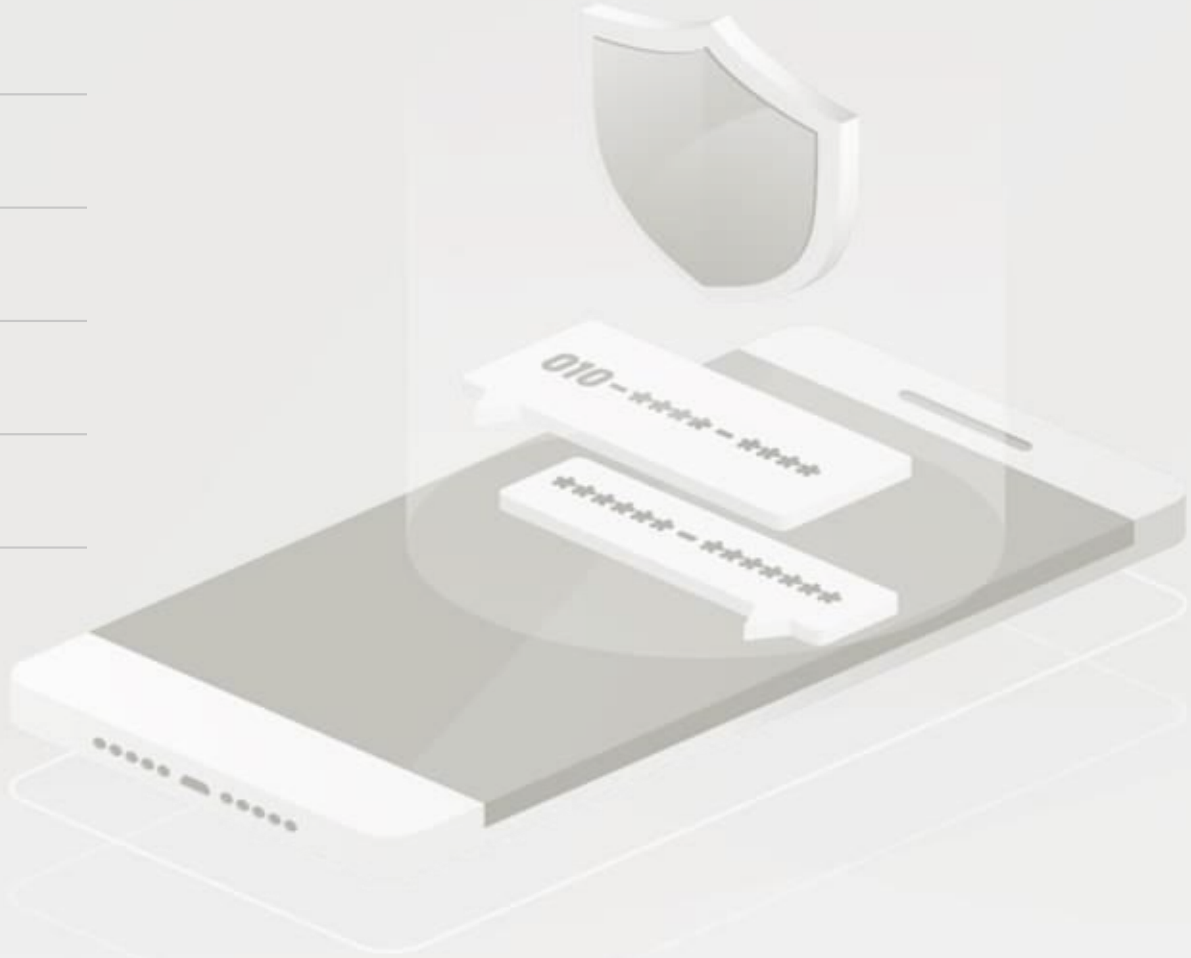

인공지능 역사

인공지능 역사

- 1936년
  - 영국의 수학자 튜링(Alan Mathison Turing)은 가상의 기계(**튜링 머신**)를 정의하고 **기호들을 읽어 스스로 처리하고 다른 상태로 전이가 가능하도록 만든다면 어떤 연산이든 스스로 처리가 가능하다**는 것을 이론적으로 증명했다. - “On Computable Numbers, with an Application to the Entscheidungsproblem”
  - 튜링 머신을 컴퓨터의 시초라고 말하는 이유는 튜링 머신을 해석해 보면 아무리 복잡하고 어려운 작업이라도 그 작업을 세부적인 단위로 반복적으로 쪼개어 가장 단순한 단위로 분해해서 연결시켜 놓으면 (범용) 튜링 머신 같은 단순한 기계 장치가 하나씩 하나씩 해결해 나가면서 복잡한 작업을 처리할 수 있기 때문이다.
- 1948년
  - 앨런 튜링은 보고서 “Intelligent Machinery”에서 범용 튜링 머신이라는 것을 사람의 지식 중에서 가장 잘 정리된 지식 중에 하나인 수학의 논리를 아주 단순한 처리를 반복해서 처리하는 기계 장치로 표현했다.
  - 결국, 사람의 지성을 분해하고 분해해서 쪼개고 쪼개면 몇 개 형태로 단순화 될 수 있지 않을까? 그러면 지능을 갖는 기계도 모방할 수 있지 않을까?라는 단서를 제시하였다.

■ 1950년 (인공지능 태동기)

- 앨런 튜링은 또한 저서 “Computing machinery and Intelligence”에서 현대 인공지능 기술에 시동을 걸었다고 평가 받는 튜링 테스트에 대한 아이디어를 제시하였다.
- 기계가 하는 말이 사람의 하는 말과 유사하다면 기계가 사람의 지능을 갖고 있다고 봐도 좋다는 것이 튜링 테스트의 핵심이다.

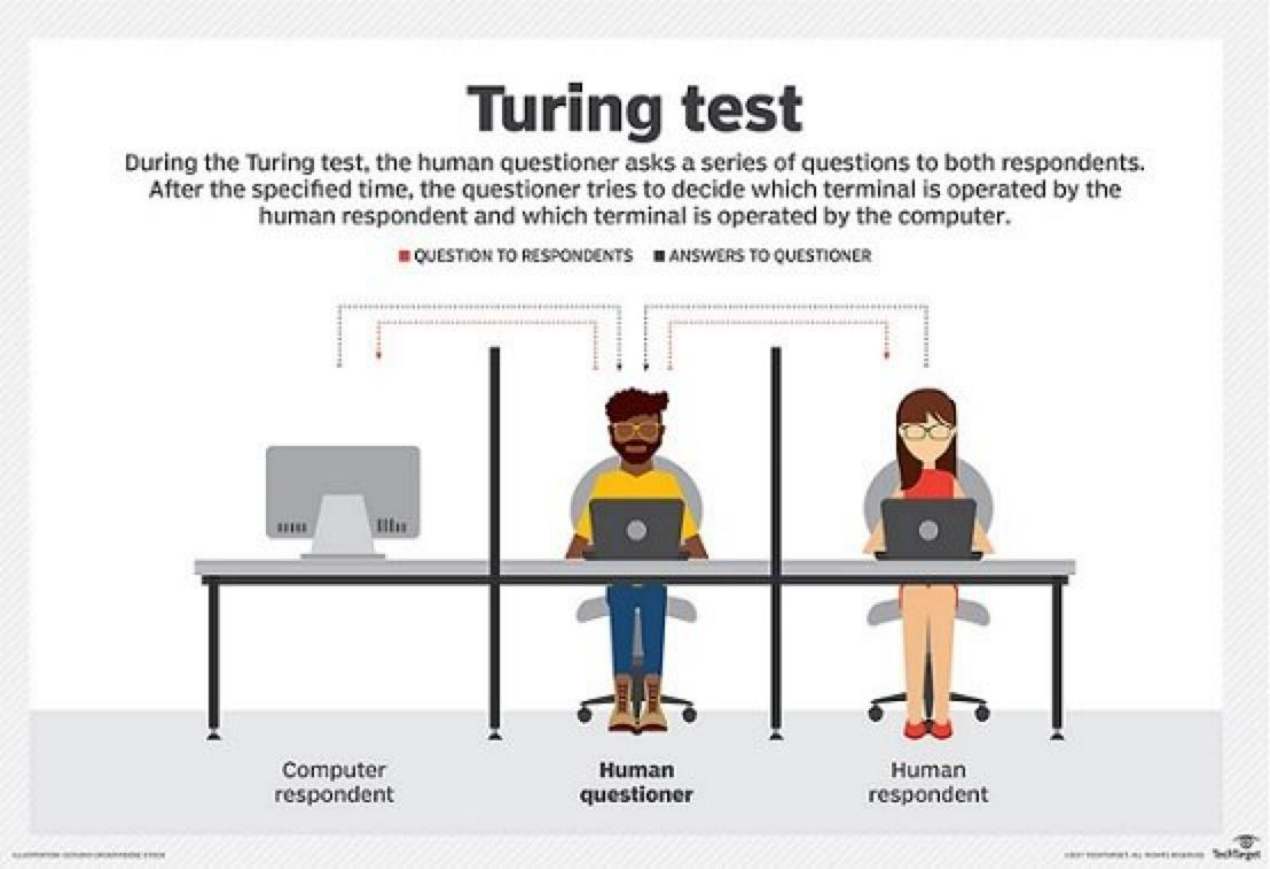

- 1946년
  - 1만 7,000여개의 진공관으로 구성된 인류 최초의 범용 컴퓨터라고 알려진 에니악(ENIAC)을 경험한 인간들은 자신들보다 수천 수만배 빠른 계산 능력을 갖춘 장치의 탄생으로부터 큰 영감을 받았을 것이다. 그런 능력이라면 여러 방면에서 인간보다 더 똑똑한 기계의 탄생도 멀지 않았다고 충분히 느낄만 했을 것이다. 그로부터 정확히 10년 뒤 미국 다트머스 대학에서 인공지능(Artificial Intelligence)란 용어를 처음으로 명명한 유명한 컨퍼런스가 개최되었다.
- 1956년
  - 당시 다트머스 대학의 수학과 부교수로 재직중인 존 매카시(John McCarthy), 대학원 시절부터 알고 지낸던 하버드 대학의 마빈 민스키(Marvin Minsky), 그리고 과거 벨 연구소에서 함께 일했던 클로드 섀넌(Claude E. Shannon), 마지막으로 IBM 연구소에 있었던 나다니엘 로체스터(Nathaniel Rochester) 이렇게 네 사람이 "인공지능에 대한 다트머스 서머 리서치 프로젝트 제안서(A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence) "를 록펠러 재단에 제출하면서 시작되게 되었다.

- 1956년 여름 다트머스 대학에서 2개월간 열린 역사적인 컨퍼런스에는 당시 컴퓨터와 인지과학 분야 선구자 20여명이 참석하여 모든 학습 과정이나 지능의 특징들을 기계도 동일하게 흉내낼 수 있다는 가정 하에 기계가 언어를 사용하는 방법, 추상화와 개념을 만드는 방법, 인간에게 주어진 다양한 문제를 풀기 위한 방법, 그리고 궁극에는 인간의 삶을 향상시키는 방법들에 대한 연구를 시작하고자 했다.
  - *We propose that a 2 month, 10 man study of artificial intelligence be carried out during the summer of 1956 at Dartmouth College in Hanover, New Hampshire.The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it.*
  - *An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves.*

A Proposal for the

DARTMOUTH SUMMER RESEARCH PROJECT ON ARTIFICIAL INTELLIGENCE

June 17 - Aug. 16

We propose that a 2 month, 10 man study of artificial intelligence be carried out during the summer of 1956 at Dartmouth College in Hanover, New Hampshire. The study is to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer.

The following are some aspects of the artificial intelligence problem:

1) Automatic Computers

If a machine can do a job, then an automatic calculator can be programmed to simulate the machine. The speeds and memory capacities of present computers may be insufficient to simulate many of the higher functions of the human brain, but the major obstacle is not lack of machine capacity, but our inability to write programs taking full advantage of what we have.

2) How Can a Computer be Programmed to Use a Language

It may be speculated that a large part of human thought consists of manipulating words according to rules of reasoning

Artificial Intelligence 용어 최초 등장 !!

- Some aspects of the artificial intelligence in Dartmouth Conf.
  - Automatic computers
  - How can a computer be programmed to use a language
  - Neuron nets
  - Theory of the size of calculation
  - Self-improvement
  - Abstractions
  - Randomness and creativity
- The proposers
  - Claude E. Shannon
  - Marvin L. Minsky
  - Nathaniel Rochester
  - John McCarthy

- 클로드 E. 섀넌
  - 수학자, 벨 전화 연구소. 섀넌은 정보의 통계이론, 개폐 교정에 대한 명제 미적분의 응용을 개발했고, 개폐 회로의 효율적인 합성, 학습하는 기계의 설계, 그리고 튜링머신의 이론에 대한 결과를 얻었다. 그와 J. McCarthy는 '자동차의 이론'에 관한 연구 수학 연보를 공동 편집 했다.
- 마빈 L. 민스키
  - 하버드 펠로우 수학 및 신경과. Minsky는 신경망에 의한 학습을 시뮬레이션하기위한 기계를 구축했으며, 학습 이론 및 랜덤 신경망 이론에 대한 결과를 포함하는"Neural Nets and the Brain Model Problem"이라는 제목의 수학으로 프린스턴 박사 논문을 작성했다.
- 나다니엘 로체스터
  - IBM Coporation, New York. 로체스터는 7년 동안 레이더의 개발과 컴퓨터 기계에 관심을 가졌다. 다른 엔지니어와 함께 현재 널리 사용되고 있는 대규모 자동 컴퓨터인 IBM Type 701의 설계를 공동 책임졌다. 그는 오늘날 널리 사용되고 있는 자동 프로그래밍 기법의 몇 가지를 고안해 냈고, 이전에는 사람에 의해서만 할 수 있었던 일을 기계가 하게 하는 방법에 관한 문제에 대해 생각해 왔다. 그는 또한 신경생리학의 이론을 시험하기 위해 컴퓨터를 사용하는 것에 특히 중점을 두고 신경망 시뮬레이션에 힘썼다.
- 존 메카시
  - 다트머스 대학의 수학 부교수. 매카시는 Turing 기계 이론, 컴퓨터 속도, 뇌 모델과 환경의 관계, 기계에 의한 언어 사용 등 사고 과정의 수학적 특성과 관련된 여러 가지 질문에 대해 연구했다. 이 작업의 일부 결과는 Shannon과 McCarthy가 편집 한 다음"Anneal Study"에 포함돼있다. McCarthy의 다른 연구는 미분 방정식 분야에서 이루어졌다.

■ 1958년 → 1차 AI붐

- 코넬 대학의 프랭크 로젠블래트(Frank Rosenblatt) 박사가 인간의 뇌 신경세포를 모방한 **퍼셉트론(Perceptron)**을 최초로 제작하여 시연을 보이면서 전세계 주목을 받았다. - Rosenblatt, Frank (1958), The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain, Cornell Aeronautical Laboratory, Psychological Review, v65, No. 6, pp. 386–408.
- 미국 해군 연구실을 가득 채우는 크기인 5톤 컴퓨터인 IBM 704에 여러 개의 펀치 카드들을 읽어 들였고 50번의 시행착오 끝에 컴퓨터는 왼쪽과 오른쪽에 마크 표시한 펀치 카드들을 구별하는 방법을 스스로 학습한 것이다.

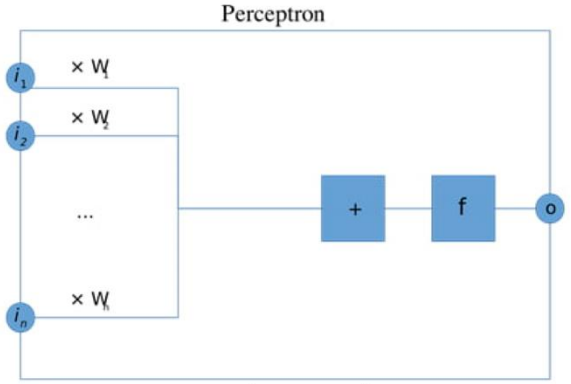

$$o = f\left(\sum_{k=1}^{n} i_k \cdot W_k\right)$$

- 이 실험은 "스스로 고유한 생각을 가질 수 있는, 즉 생각할 수 있는 최초의 기계"였던 '퍼셉트론'의 시연이었다.

■ 1969년

– 마빈 민스키가 퍼셉트론은 결국 선형 분류기에 불과하기 때문에 XOR 분류도 못한다는 것을 수학적으로 증명함으로써 한동안 인공 신경망을 포함한 인공지능 연구가 빙하기를 맞이하게 된다. - Minsky M. L. and Papert S. A. 1969. *Perceptrons*. Cambridge, MA: MIT Press.

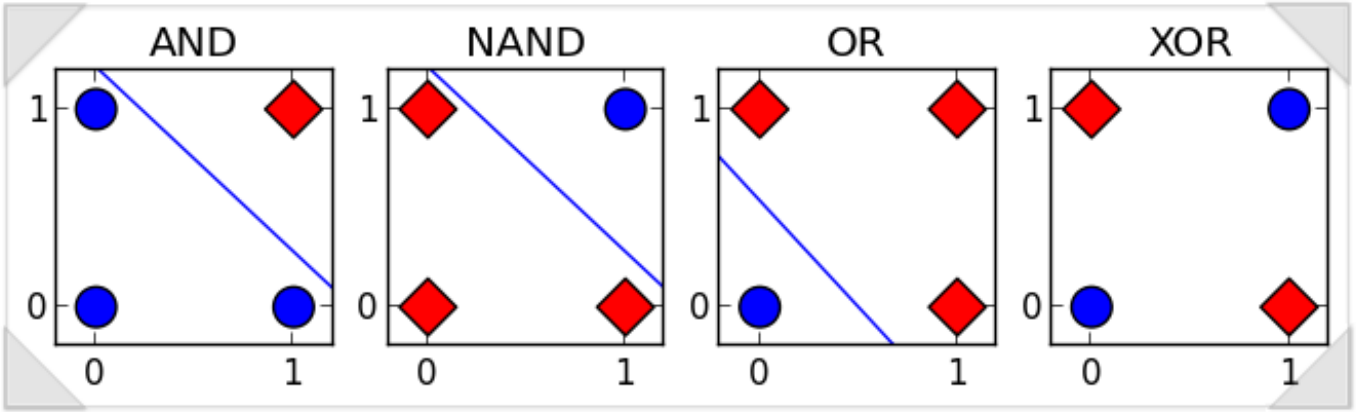

– 다층 퍼셉트론 모델(MLP)이 XOR 문제를 해결할 수 있을 것이라고 예상했으나 적절한 weight와 bias 값을 찾는 방법이 없다는 것을 지적하게 된다.

– 이후 1970년대를 거쳐 80년대 중반까지 다층 퍼셉트론은 범접할 수 없는 영역으로 남아 있었다.

■ 1986년 → 제 2차 AI 붐의 시작

- 캘리포니아 대학의 데이비드 럼멜하트, 카네기 멜론 대학의 **제프리 힌튼**, 노스이스턴 대학의 로널드 윌리엄스가 오류 역전파 알고리즘으로 은닉층을 갖는 다층 퍼셉트론을 학습시키는데 성공한다.
- 이것은 최초 발견은 아니었고 이미 170년대 수학분야에서 후진 자동 미분 기법이 존재하였고 1974년 하버드 대학교 학생이었던 폴 웨어보스(Paul John Werbos)가 후진 자동 미분에서 영감을 얻어 오류 역전파 알고리즘으로 다층 퍼셉트론을 학습시키는 방법으로 박사학위를 발표한 바 있다.
- 그러나 신경망이 다시 집중적인 관심을 받으며 다시 인공지능의 해빙기를 맞이한 것은 1986년 럼멜하트 논문이 발표된 이후라고 볼 수 있다.
- 1980년대 후반기부터 인공 신경망으로 기반으로 한 연구와 상용화가 꾸준히 시도되었다.
- 그러나 1990년대 후반에 접어들면서 신경망의 계산 복잡도가 당시 하드웨어로 감당하기에는 너무 크고 학습에 사용될 데이터도 충분하지 않았기 때문에 연구에 큰 진전을 보지 못하고 다시 한번 쇠락을 길을 걷게 된다.

- 2006년
  - 제프리 힌튼 교수는 “A fast learning algorithm for deep belief nets’라는 논문을 발표합니다. 이 논문(Deep Belief Network, DBN)은 새로운 알고리즘으로 기존 신경망의 한계를 극복하고, 본격적인 딥러닝의 시대를 개척하기 시작한다.
  - DBN는 이전에 자신이 테리 세이노프스키와 함께 제안했던 볼츠만 머신을 여러 층으로 쌓아 올린 형태의 새로운 신경망 구조로 기울기 소실 문제 등을 해결하였다.
- 2012년 → 제 3차 AI 붐의 시작
  - 인공 신경망이 쇠락을 길을 걷다가 다시 한번 부상을 한 것은 2012년 이미지넷(ImageNet) 대회를 통해서 이루어졌다. 당시까지만 해도 이미지 인식과 관련한 세계 최고 기술들은 25% 이상의 오류를 기록하고 있었다. 그런데 토론토 대학의 제프리 힌튼(jeffrey Hinton) 교수 팀이 AlexNet이라는 심층신경망(Deep Neural Network)을 이용하여 15.31%라는 오류율을 달성함으로써 이 분야의 연구자들을 깜짝 놀라게 하였다.
  - 이 사건 이후 인공 신경망에 대한 연구가 다시 주목을 받게 되었다.

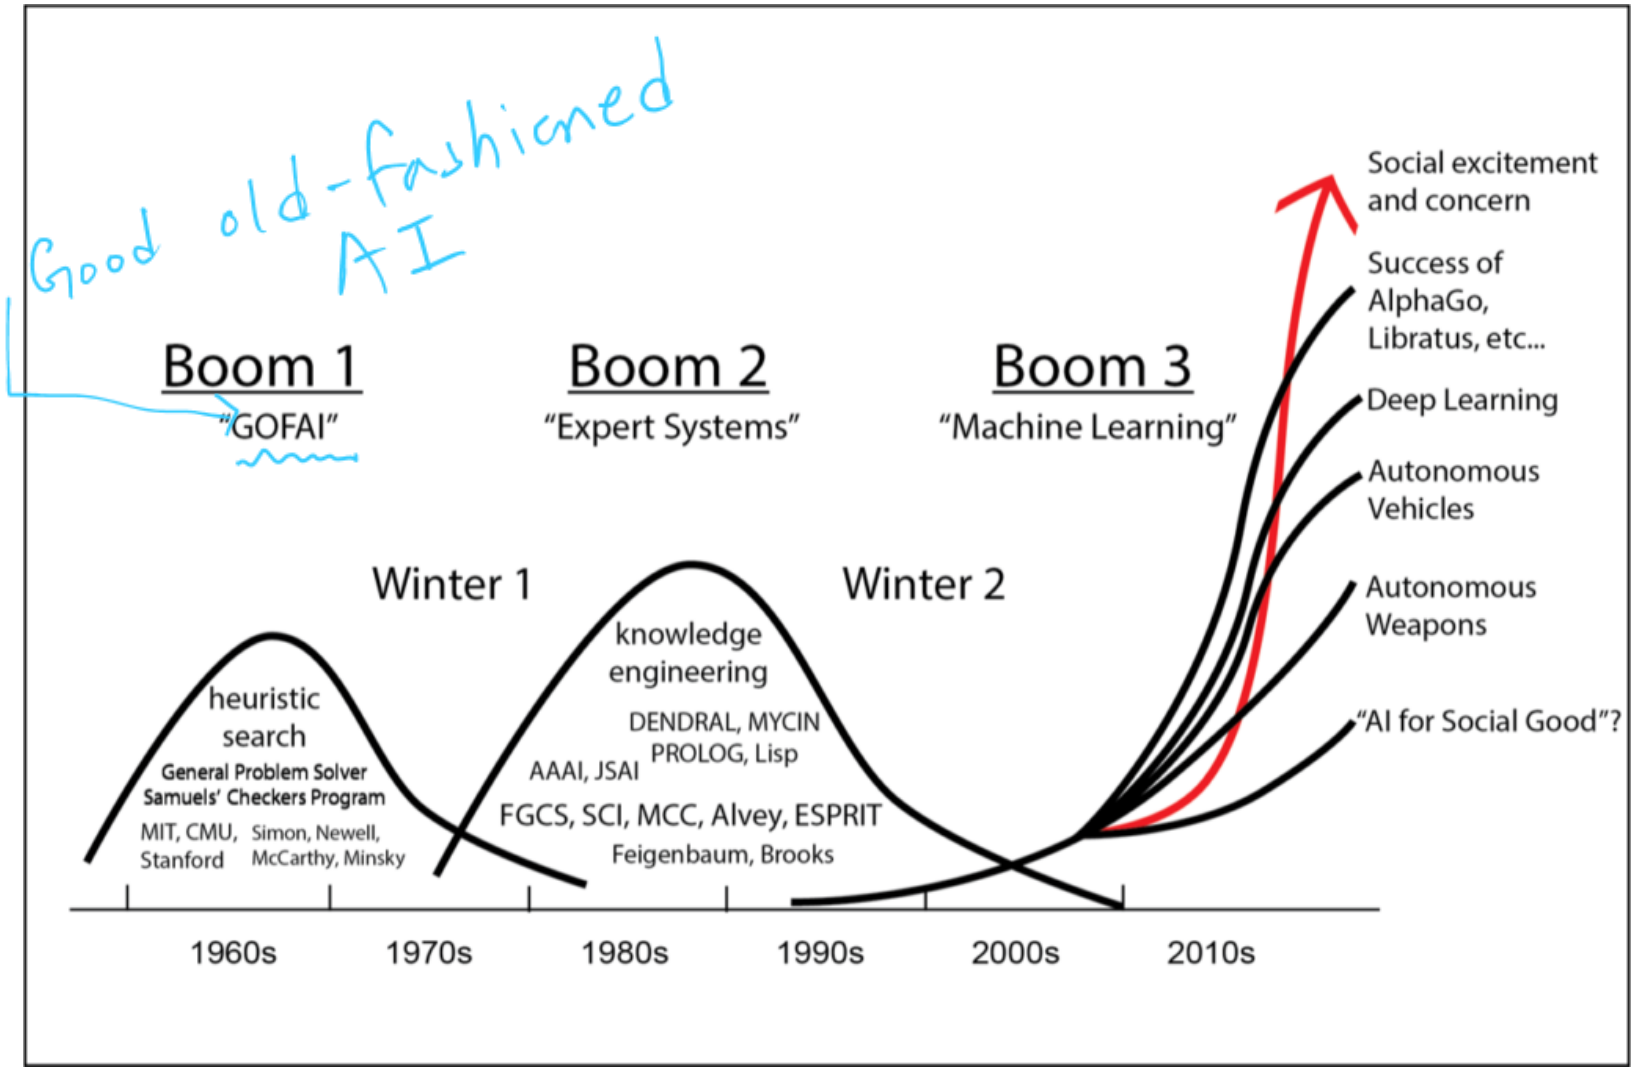
Good old-fashioned AI
Boom 1
"GOFAI"
Boom 2
"Expert Systems"
Boom 3
"Machine Learning"
Winter 1
Winter 2
heuristic search
General Problem Solver
Samuels' Checkers Program
MIT, CMU, Stanford
Simon, Newell, McCarthy, Minsky
knowledge engineering
DENDRAL, MYCIN
PROLOG, Lisp
AAAI, JSAI
FGCS, SCI, MCC, Alvey, ESPRIT
Feigenbaum, Brooks
Social excitement and concern
Success of AlphaGo, Libratus, etc...
Deep Learning
Autonomous Vehicles
Autonomous Weapons
"AI for Social Good"?
1960s
1970s
1980s
1990s
2000s
2010s

02

인공지능 연구 분야
- 지식 표현과 추론
- 기계학습

지식의 표현

- 지식표현(knowledge representation)
  - 문제 해결에 이용하거나 심층적 추론을 할 수 있도록 지식을 효과적으로 표현하는 방법
    - IF-THEN 규칙(rule)
    - 프레임(frame)
    - 의미망(semantic net)
    - 논리(logic) : 명제논리(propositional logic), 술어논리(predicate logic)
    - 스크립트
    - 불확실한 지식 표현하는 확률적 방법

추론

- 추론(inference)
  - 가정이나 전제로부터 결론을 이끌어내는 것
  - 규칙기반 시스템의 추론
    - 전향 추론(forward inference)
    - 후향 추론(backward inference)
  - 확률 모델의 추론
    - 관심 대상의 확률 또는 확률분포를 결정하는 것
    - 베이즈 정리(Bayesian theorem) 등

기계학습

- 기계학습(Machine Learning)의 정의
  - Arthur Lee Samuel (1959): Machine Learning is the field of study that gives the computer the ability to learn without being explicitly programmed. - *"Some studies in Machine Learning Using the Game of Checkers", IBM Journal of Research and Development, 1959.*

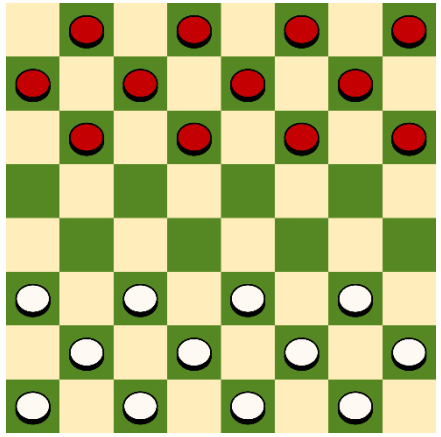

Photos from Wikipedia

– Tom Mitchell (1998): a computer program is said to learn from *experience E* with respect to some class of *tasks T* and *performance measure P*, <u>if its performance at tasks in T, as measured by P, improves with experience E</u>.
  - Experience (data): games played by the program (with itself)
  - Performance measure: winning rate

Image from Tom Mitchell's homepage

기계학습의 분류

Supervised Learning

Unsupervised Learning

Reinforcement Learning

can be viewed as tasks

기계학습의 분류

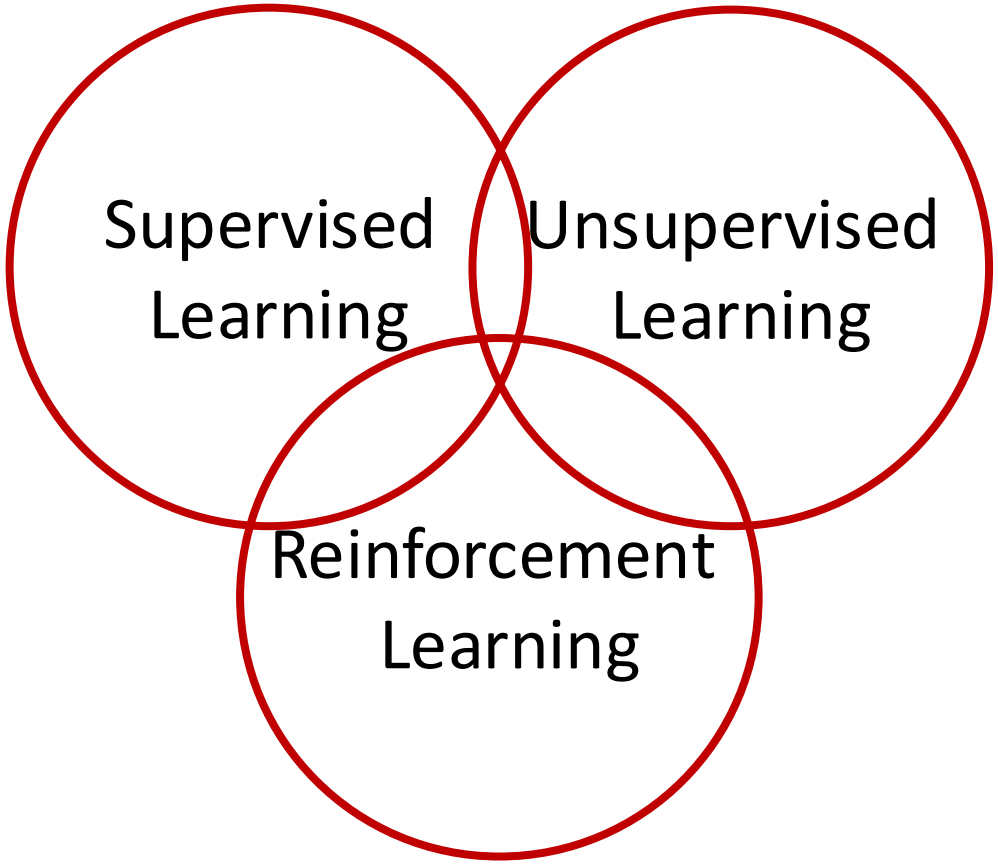

can also be viewed as tools/methods

03

지도학습(Supervised Learning)

Housing Price Prediction

- Given: a dataset that contains n samples
$$\left(x^{(1)}, y^{(1)}\right), \ldots \left(x^{(n)}, y^{(n)}\right)$$
- Task: if a residence has x square feet, predict its price?

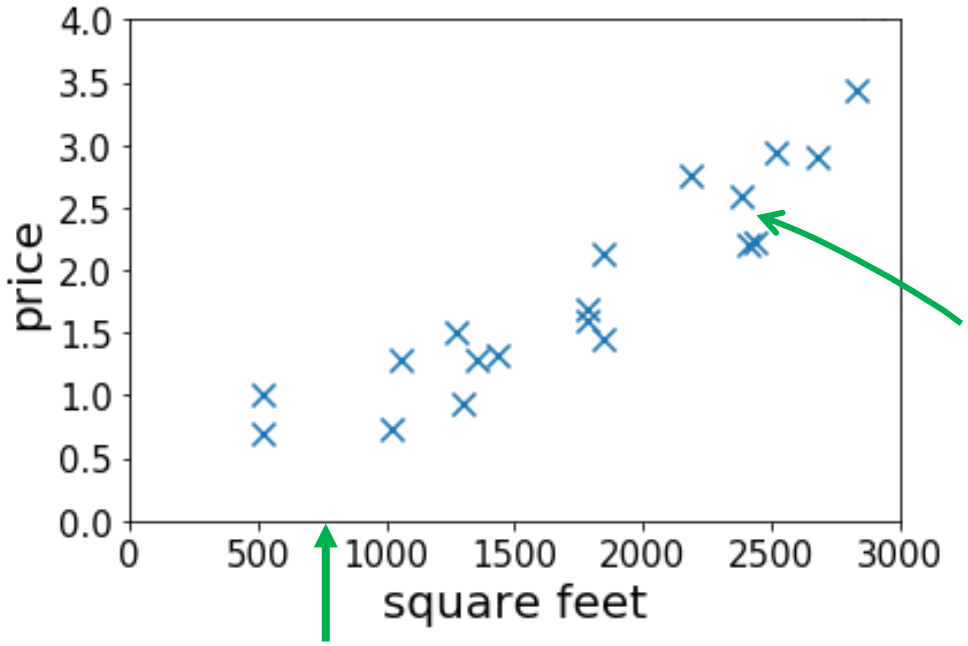

15th sample
$(x^{(15)}, y^{(15)})$

$x = 800$
$y = ?$

Housing Price Prediction

- Given: a dataset that contains n samples
$$\left(x^{(1)}, y^{(1)}\right), \ldots \left(x^{(n)}, y^{(n)}\right)$$
- Task: if a residence has x square feet, predict its price?

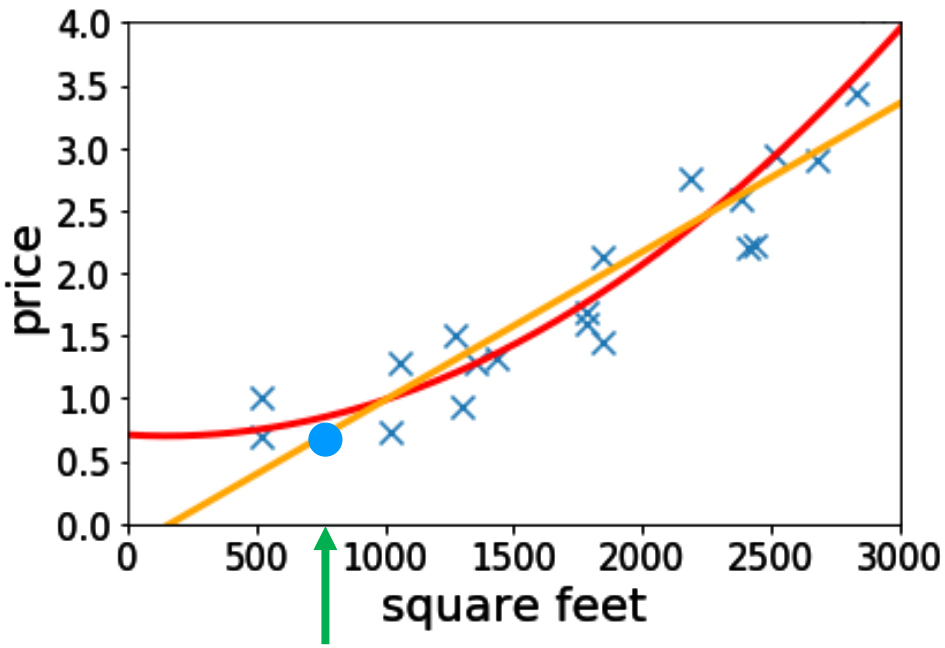

$$x = 800$$
$$y = ?$$

More Features

- Suppose we also know the lot size
- Task: find a function that maps

$$\text{(size, lot size)} \rightarrow \text{price}$$

features/input $x \in \mathbb{R}^2$

label/output $y \in \mathbb{R}$

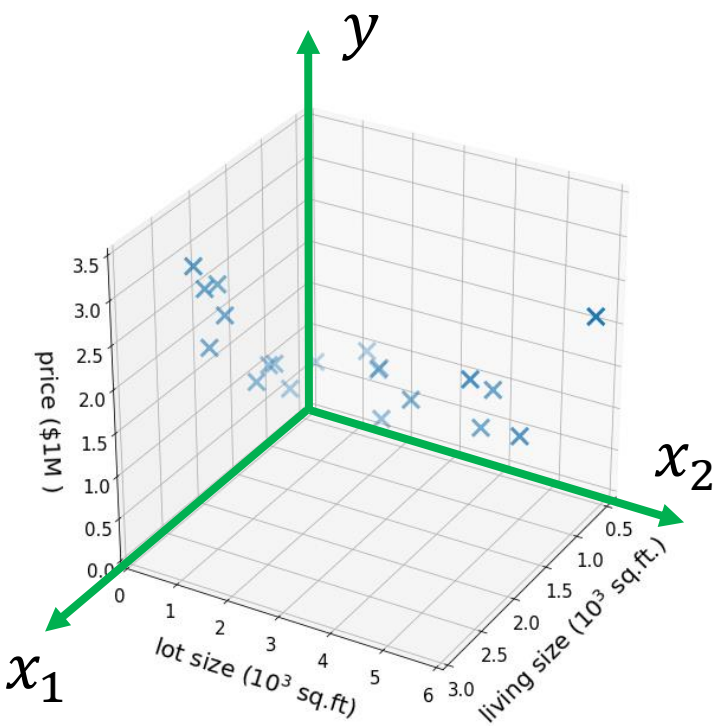

- Dataset: $\left(x^{(1)}, y^{(1)}\right), \ldots, \left(x^{(n)}, y^{(n)}\right)$

where $x^{(i)} = \left(x_1^{(i)}, x_2^{(i)}\right)$

- "Supervision" refers to $y^{(1)}, \ldots, y^{(n)}$

High-dimensional Features

- $x \in \mathbb{R}^d$ for large d
- E.g.,

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ \vdots \\ \vdots \\ x_d \end{bmatrix} \begin{array}{l} \text{--- living size} \\ \text{--- lot size} \\ \text{--- \# floors} \\ \text{--- condition} \\ \text{--- zip code} \\ \vdots \end{array} \longrightarrow \quad y \quad \text{--- price}$$

Regression vs Classification

- Regression: if $y \in \mathbb{R}$ is a continuous variable
  - e.g., price prediction
- Classification: the label is a discrete variable
  - e.g., the task of predicting the types of residence

(size, lot size) → house or townhouse?

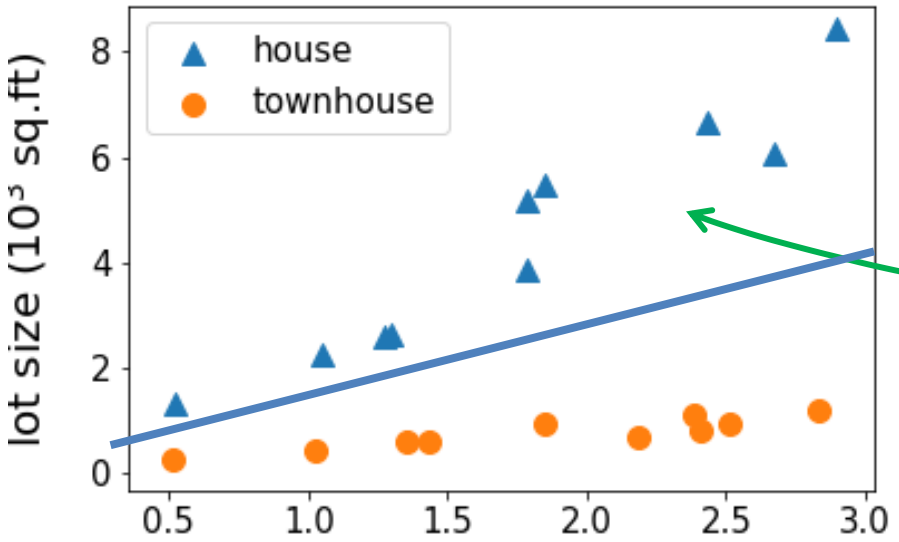

y = house or townhouse?

Supervised Learning in Computer Vision

- Image Classification
  - x = raw pixels of the image, y = the main object

ImageNet Large Scale Visual Recognition Challenge. Russakovsky et al.'2015

Supervised Learning in Computer Vision

- Object localization and detection
  - x = raw pixels of the image, y = the bounding boxes

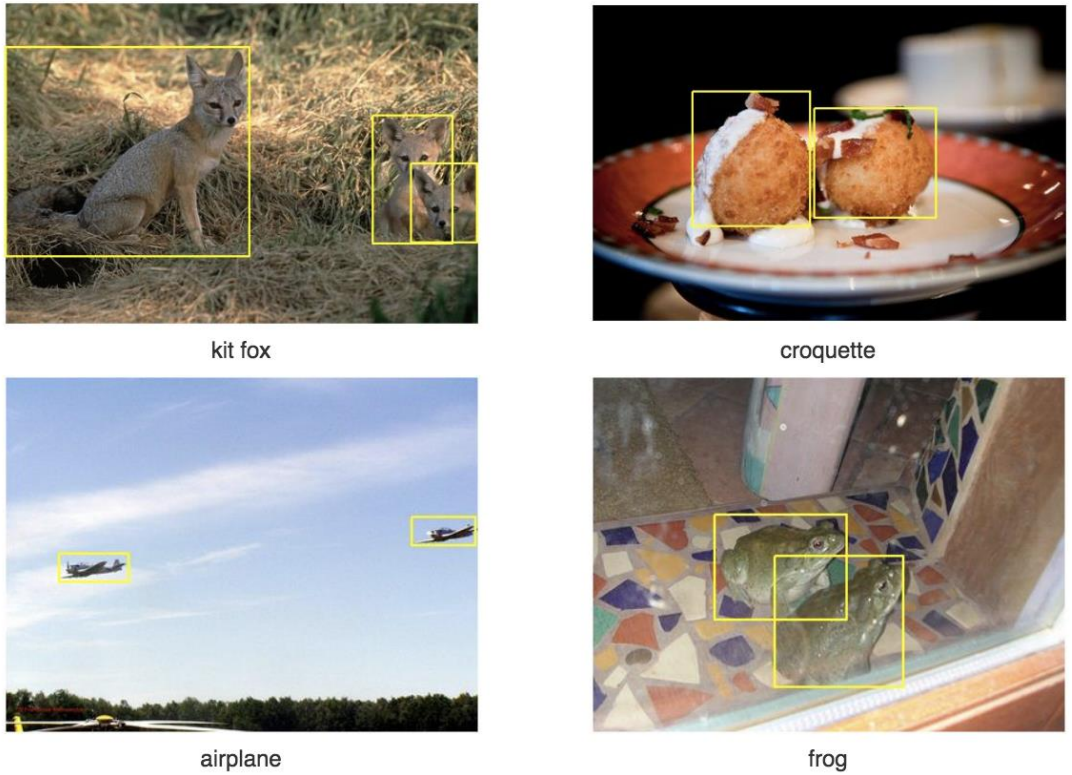

ImageNet Large Scale Visual Recognition Challenge. Russakovsky et al.'2015

Supervised Learning in Natural Language Processing

- Machine translation

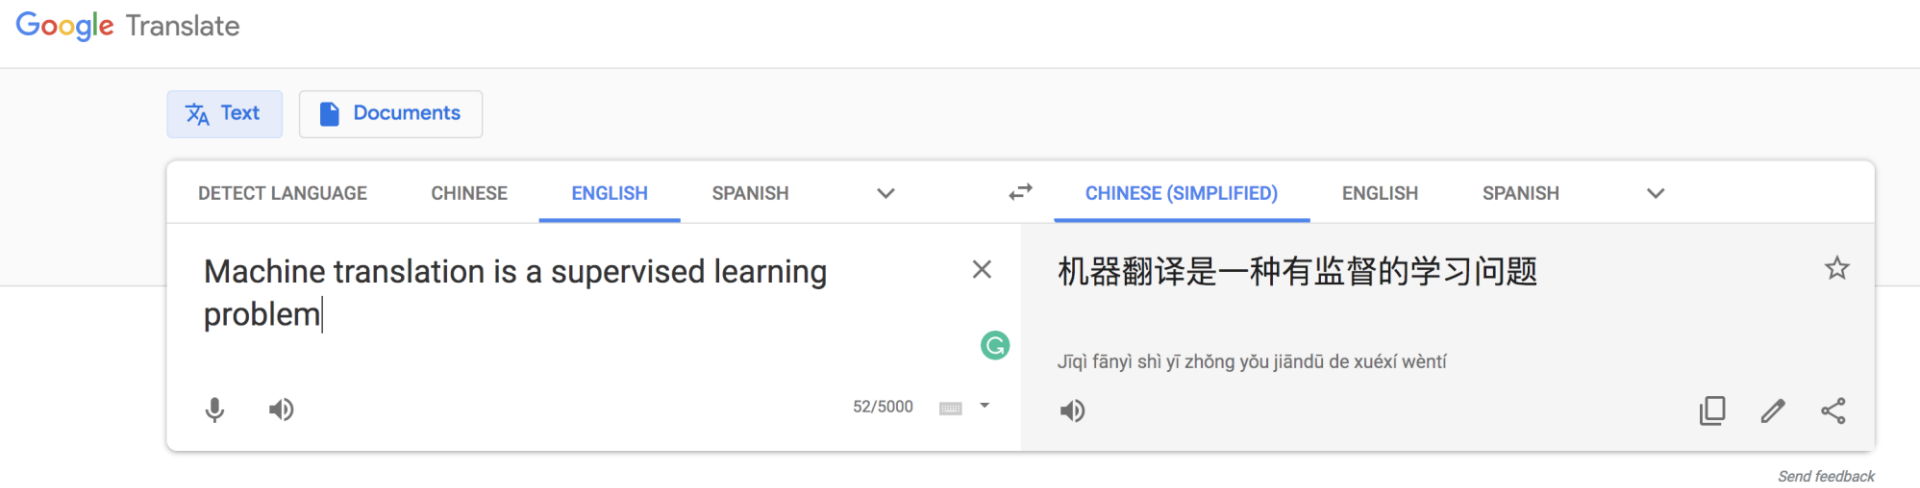

04

비지도학습(Unsupervised Learning)

Unsupervised Learning

- Dataset contains no labels: $x^{(1)}, \dots x^{(n)}$
- Goal (vaguely-posed): to find interesting structures in the data

supervised

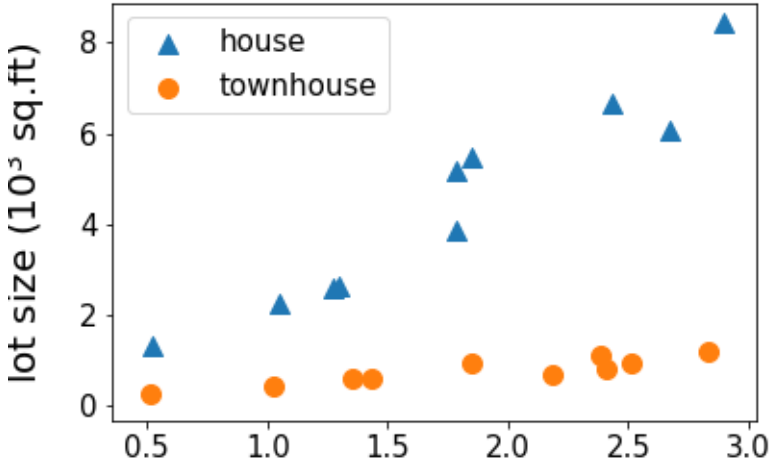

unsupervised

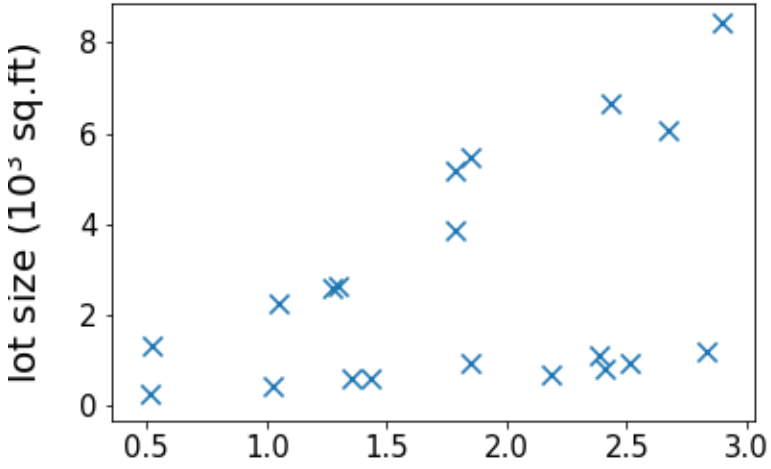

Clustering

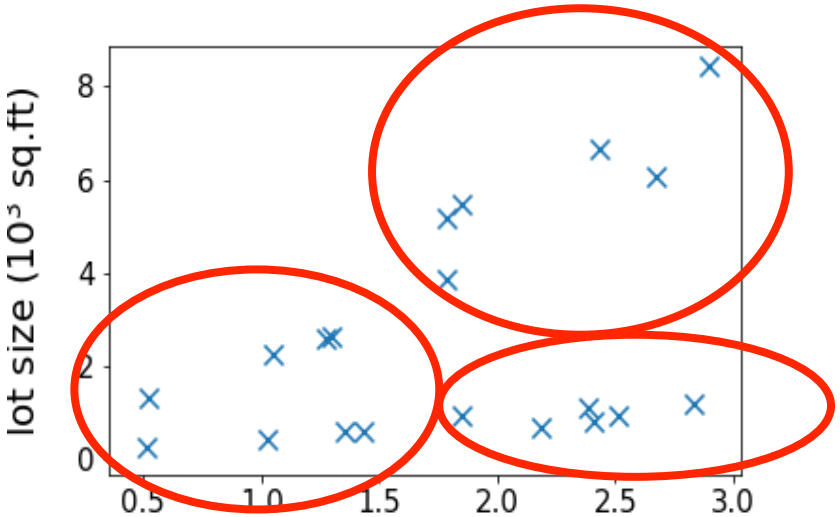
lot size (10³ sq.ft)
0
2
4
6
8
0.5
1.0
1.5
2.0
2.5
3.0

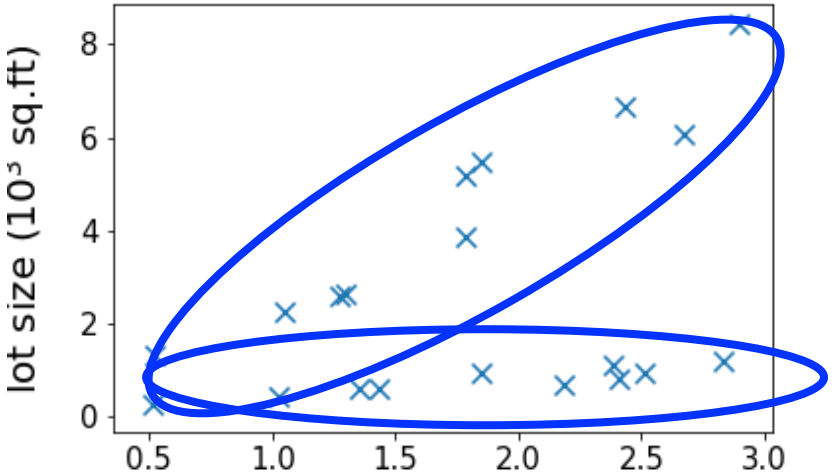
lot size (10³ sq.ft)
0
2
4
6
8
0.5
1.0
1.5
2.0
2.5
3.0

Clustering Genes

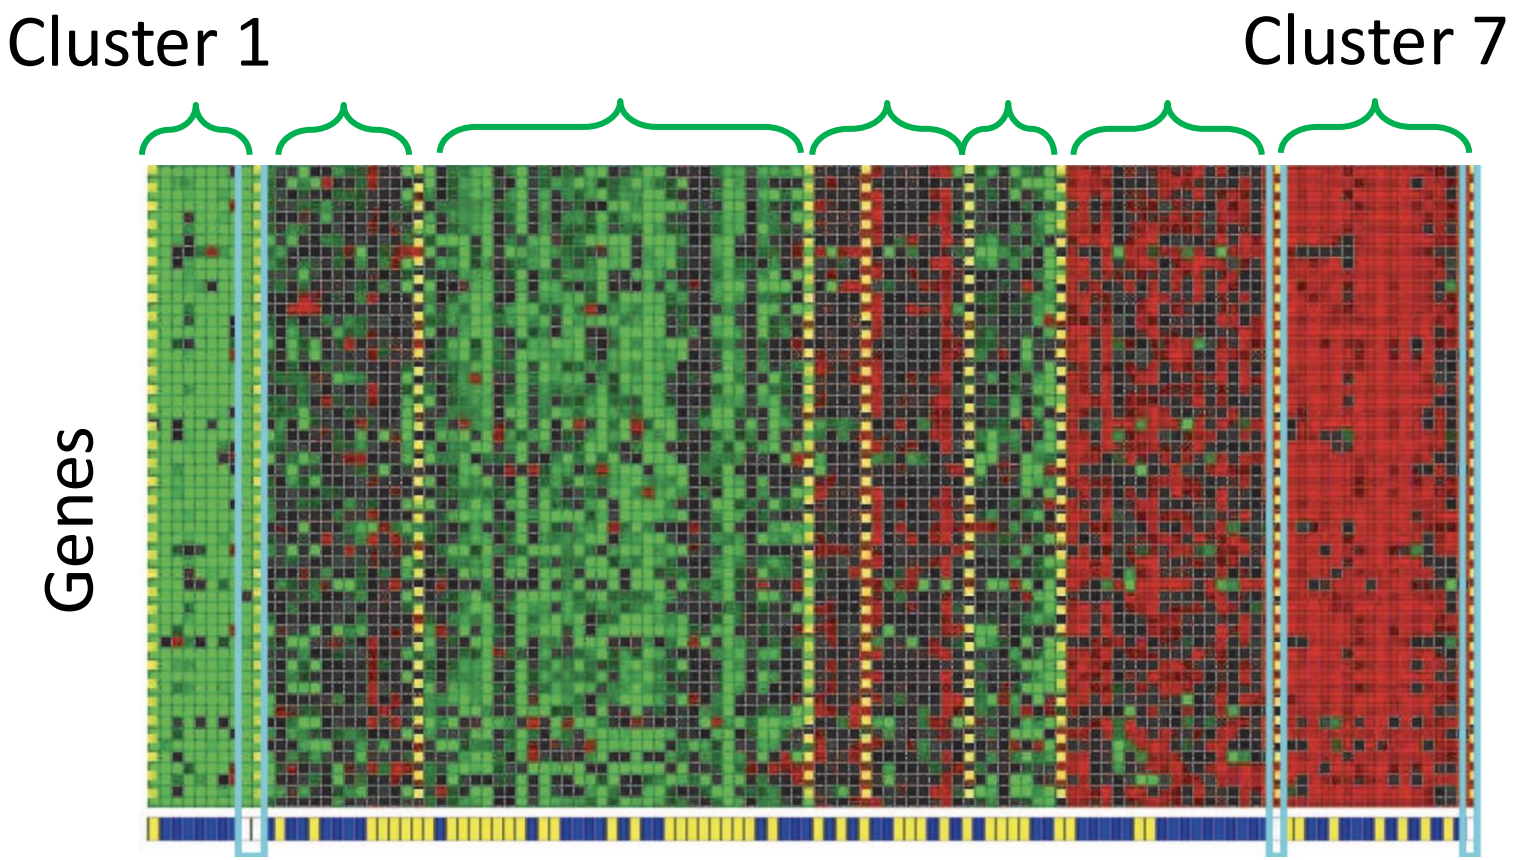

Identifying Regulatory Mechanisms using Individual Variation Reveals Key Role for Chromatin Modification. [Su-In Lee, Dana Pe'er, Aimee M. Dudley, George M. Church and Daphne Koller. ’06]

Latent Semantic Analysis (LSA)

documents

words

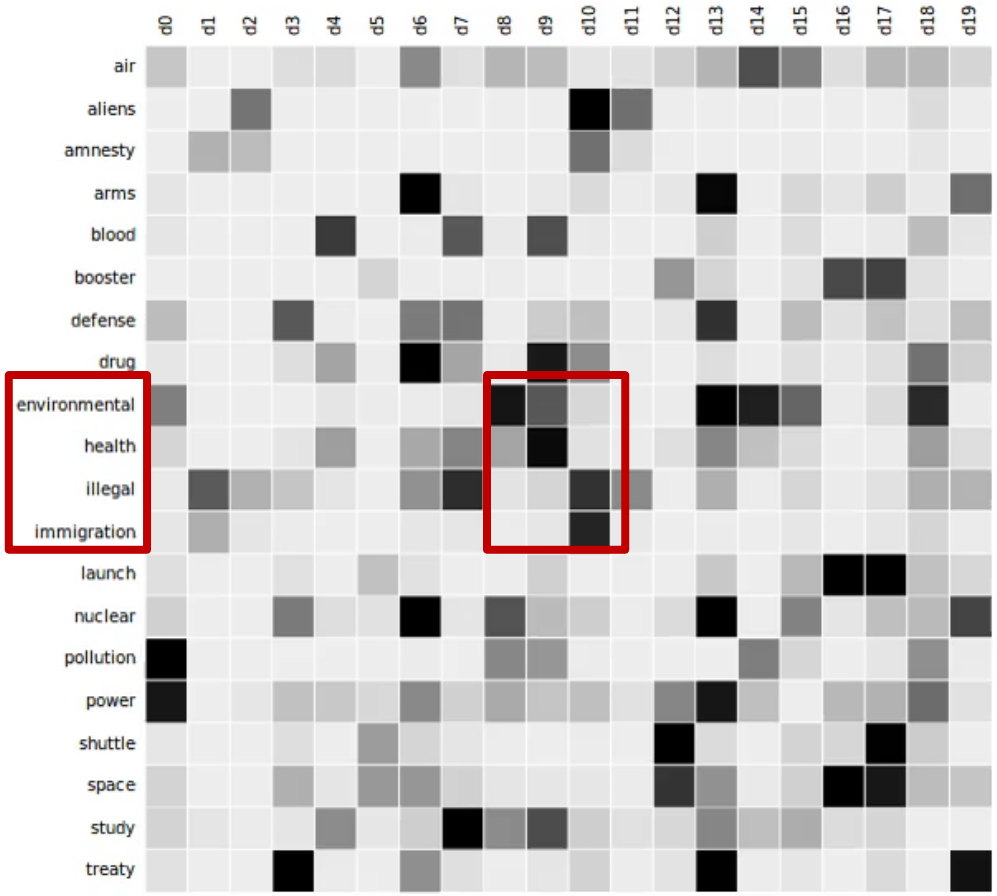

principal component analysis (tools used in LSA)

Image credit: https://commons.wikimedia.org/wiki/File:Topic_detection_in_a_document-word_matrix.gif

Word Embeddings

Represent words by vectors

- word $\xrightarrow{\text{encode}}$ vector
- relation $\xrightarrow{\text{encode}}$ direction

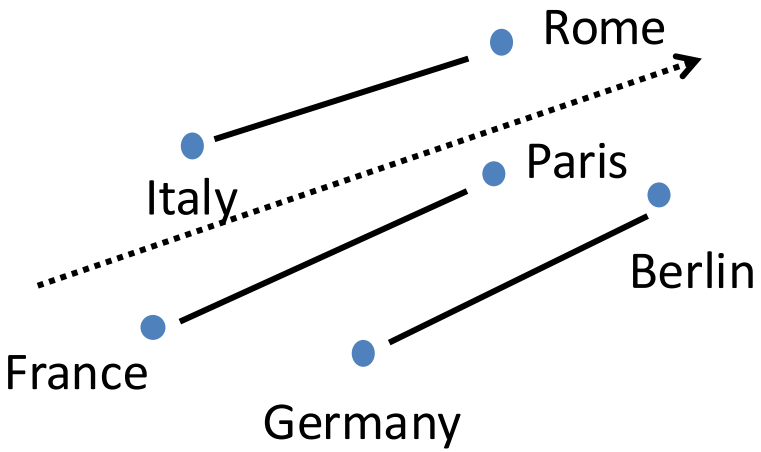

Unlabeled dataset

Word2vec [Mikolov et al'13]
GloVe [Pennington et al'14]

Clustering Words with Similar Meanings (Hierarchically)

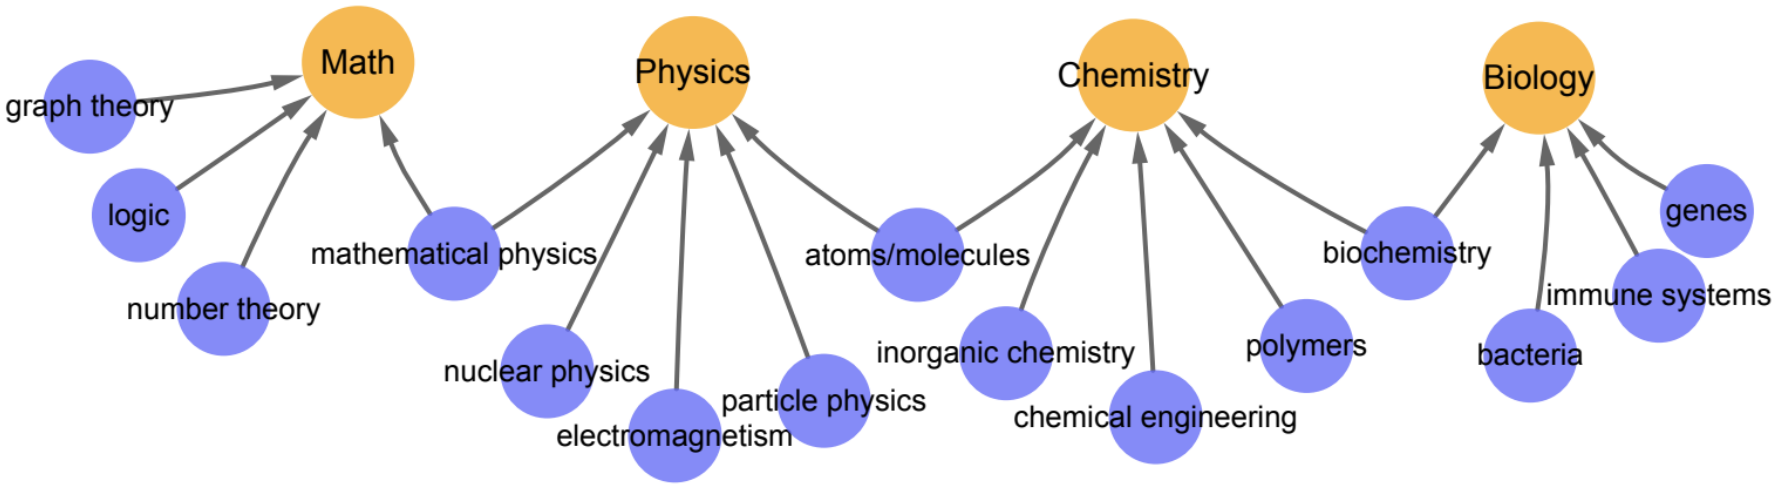

	logic deductive propositional semantics	graph subgraph bipartite vertex	boson massless particle higgs	polyester polypropylene resins epoxy	acids amino biosynthesis peptide
tag	*logic*	*graph theory*	*particle physics*	*polymer*	*biochemistry*

[Arora-Ge-Liang-M.-Risteski, TACL'17,18]

05

강화학습(Reinforcement Learning)

강화학습

- The algorithm can collect data interactively

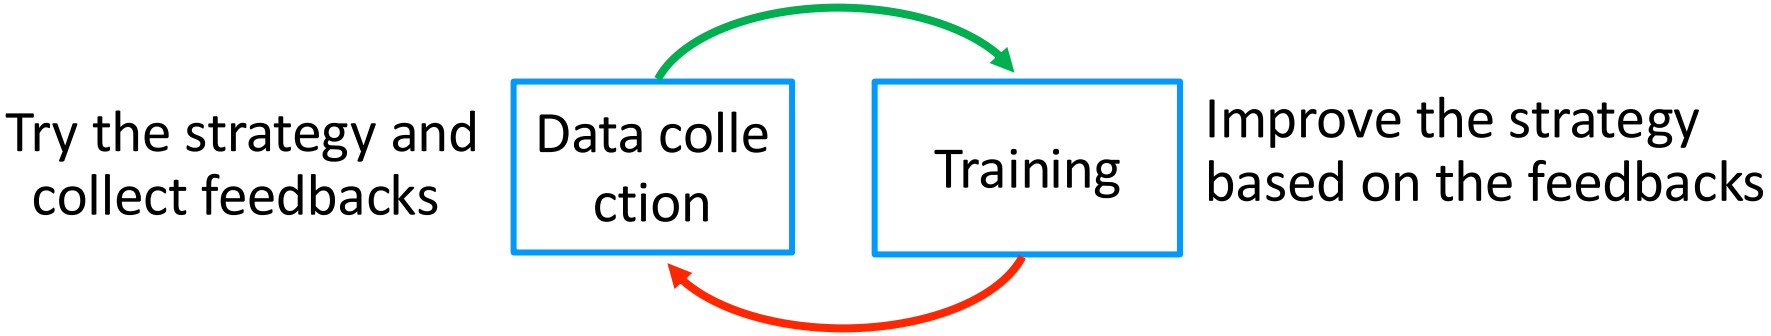

learning to walk to the right

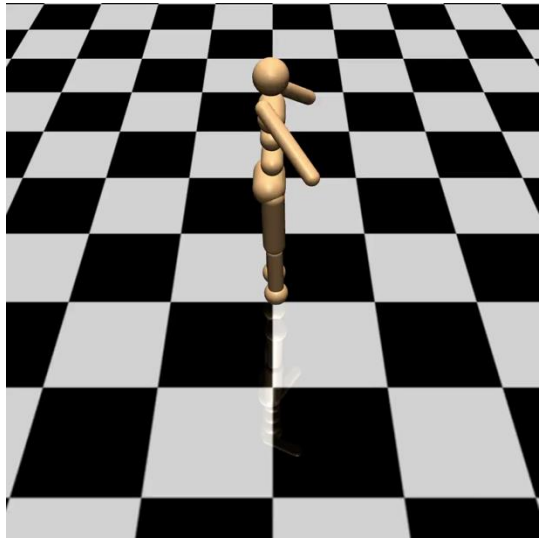

[Luo-Xu-Li-Tian-Darrell-M.'18]

learning to walk to the right

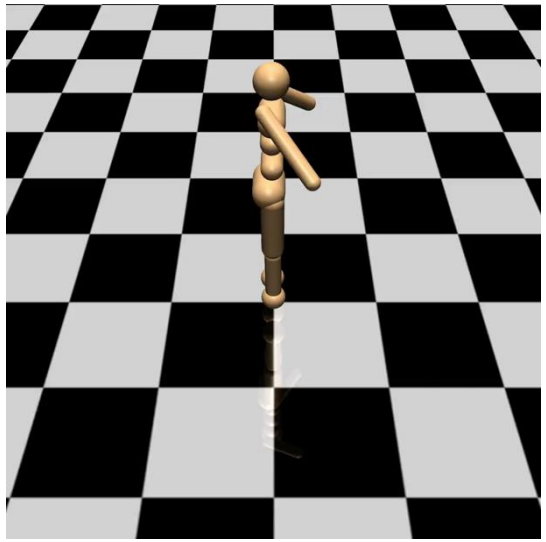

Iteration 20

[Luo-Xu-Li-Tian-Darrell-M.'18]

데이터사이언스

Very Short History of Data Science

1962 W. Tukey writes in "The Future of Data Analysis": I have come to feel that my central interest is in *data analysis*... Data analysis, and the parts of statistics which adhere to it, must...take on the characteristics of science rather than those of mathematics... data analysis is intrinsically an empirical science... In 1977, Tukey published *Exploratory Data Analysis*, arguing that more emphasis needed to be placed on using data to suggest hypotheses to test and that Exploratory Data Analysis and Confirmatory Data Analysis " can—and should—proceed side by side."

1974 Peter Naur publishes *Concise Survey of Computer Methods* in Sweden and the United States. The Preface to the book tells the reader that a course plan was presented at the IFIP Congress in 1968, titled "Datalogy, the science of data and of data processes and its place in education," and that in the text of the book, "the term 'data science' has been used freely. Naur offers the following definition of data science: "The science of dealing with data, once they have been established, while the relation of the data to what they represent is delegated to other fields and sciences.

September 1994 *BusinessWeek* publishes a cover story on "Database Marketing": "Companies are collecting mountains of information about you, crunching it to predict how likely you are to buy a product, and using that knowledge to craft a marketing message precisely calibrated to get you to do so...

2001 William S. Cleveland publishes "Data Science: An Action Plan for Expanding the Technical Areas of the Field of Statistics." It is a plan "to enlarge the major areas of technical work of the field of statistics. Because the plan is ambitious and implies substantial change, the altered field will be called 'data science.'"

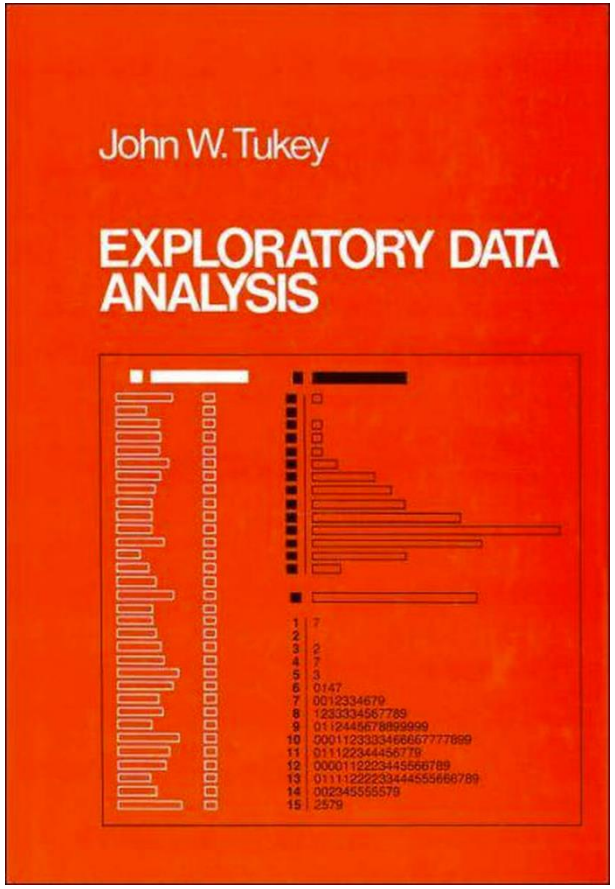

Source: https://whatsthebigdata.com/2012/04/26/a-very-short-history-of-data-science/

Very Short History of Data Science

January 2009 Hal Varian, Google's Chief Economist, tells the *McKinsey Quarterly*: "I keep saying the sexy job in the next ten years will be statisticians.

May 2009 Mike Driscoll writes in "The Three Sexy Skills of Data Geeks": "...with the Age of Data upon us, those who can model, munge, and visually communicate data—call us statisticians or data geeks—are a hot commodity."

September 2010 Hilary Mason and Chris Wiggins write in "A Taxonomy of Data Science": "...we thought it would be useful to propose one possible taxonomy... of what a data scientist does, in roughly chronological order: Obtain, Scrub, Explore, Model, and iNterpret...."

September 2010 Drew Conway writes in "The Data Science Venn Diagram":

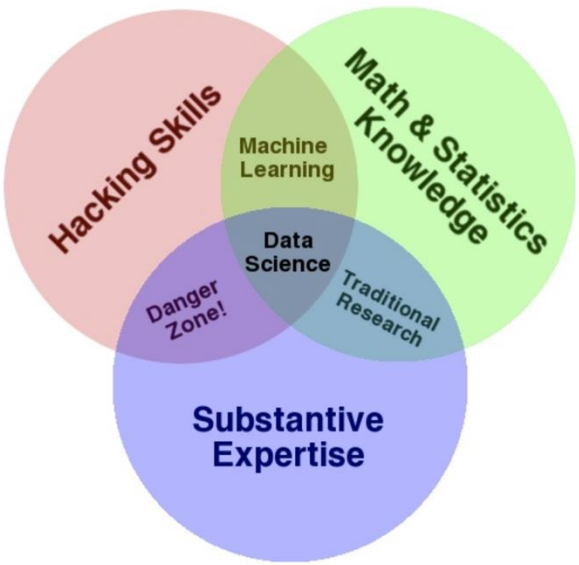

September 2011 Harlan Harris writes in "Data Science, Moore's Law, and Moneyball" : "'Data Science' is defined as what 'Data Scientists' do. What Data Scientists do has been very well covered, and it runs the gamut from data collection and munging, through application of statistics and machine learning and related techniques, to interpretation, communication, and visualization of the results.

September 2012 Tom Davenport and D.J. Patil publish "Data Scientist: The Sexiest Job of the 21st Century" in the *Harvard Business Review*.

Data Science

Inter-disciplinary field that uses scientific methods, proc
esses, algorithms and systems to extract knowledge an
d insight from many structural and unstructured data

- From Wikipedia

Data Scientist

- "A data scientist is someone who knows more statistics than a computer scientist and more computer science than a statistician." - *Josh Blumenstock*
- "Data Scientist = statistician + programmer + coach + storyteller + artist" - *Shlomo Aragmon*

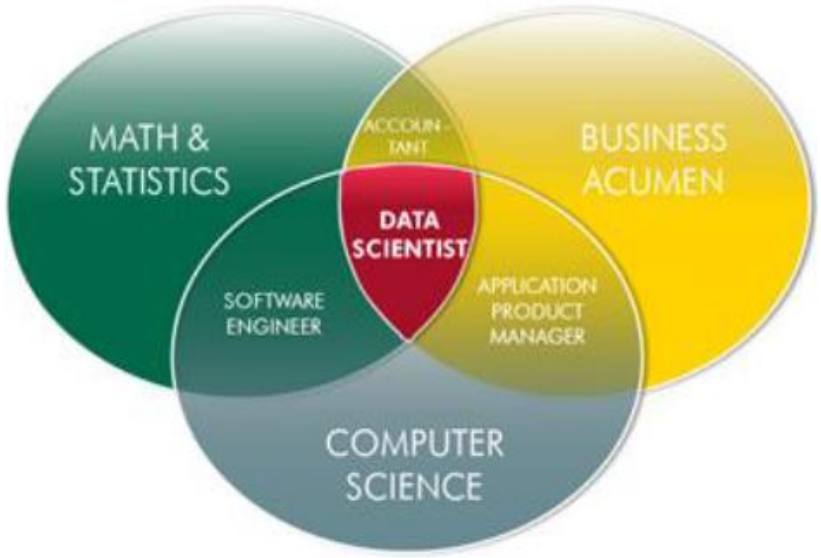

Data Science Applications

Shopping:
How does Amazon forecast how many items it needs to store in its warehouses?

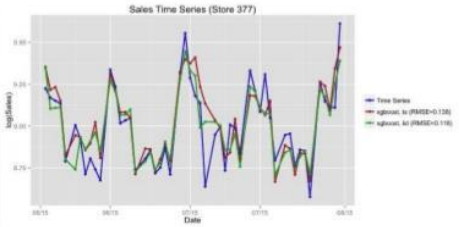

From cdn.wonderfulengineering.com (top), formaspace.com (bottom) and linkedin.com (right)

Medicine: How can genomics help to personalize medical recommendations?

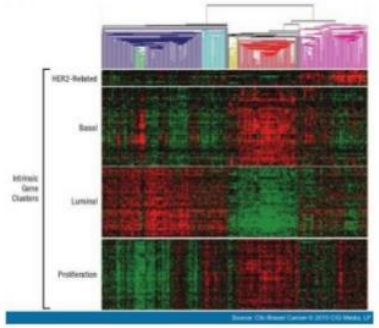

Data Matrix:
Rows = genes, Columns = patients

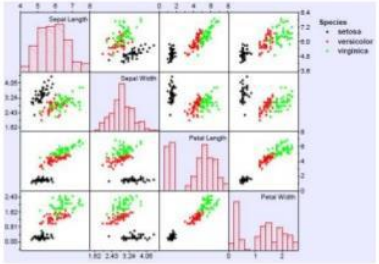

Sports: How do we visualize and understand massive amounts of game sensor data?

Graphics from www.stats.com/sportvu/sportvu.asp

Social media: How does Facebook recognize people in images?

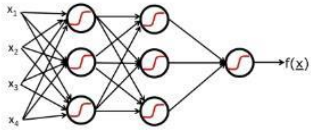

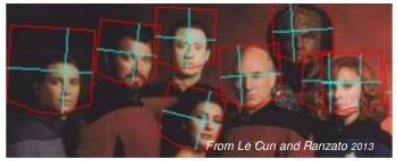

From Le Cun and Ranzato 2013

신용카드회사

비자(VISA)의 경우 구입품목, 시점, 결제 위치 등을 실시간으로 파악하고 고객의 구매이력 및 성향을 감안하여 인근 가맹점의 할인쿠폰을 발송해 주는 RTM(Real Time Messaging) 서비스를 제공하고 있다. 이 결과 카드이용건수 및 가맹점 신규고객이 증가하는 결과를 얻었다. 또한, 고객의 카드이용 패턴을 실시간 분석하여 카드 부정사용을 사전에 차단하는 시스템을 빅데이터 기술을 활용하여 개발/운영하고 있다.

아멕스(AMEX)에서는 위치 기반 소셜네트워크 정보를 활용한 고객별 맞춤형 마케팅을 실시해 고객들로부터 긍정적인 반응을 얻고 있다. AMEX Sync 프로그램은 제휴를 맺은 소셜 플랫폼의 고객 계정을 AMEX카드와 연동시켜 고객에게 맞춤형 할인 혜택을 준다. 예를 들면 페이스북이나 트위터에서 특정 상품 및 레스토랑에 '좋아요'를 클릭하면 할인쿠폰 및 관련 정보를 미리 제공해줌으로써 기존의 타깃 마케팅보다 큰 효과를 얻을 수 있었다.

삼성카드에서도 빅데이터를 활용하여 맞춤형 할인 혜택을 주는 링크(LINK)서비스를 제공하고 있다. 고객의 카드 거래실적을 분석하여 앞으로 자주 이용할 것으로 예상되는 가맹점 혜택을 미리 고객에게 제안하고 고객이 별도의 쿠폰이나 할인권을 제시하지 않아도 결제만 하면 자동으로 혜택을 적용 받을 수 있는 서비스이다. 이로 인해 기존의 문자메시지 및 타깃 마케팅에 비해 구매율이 높았고, 가맹점의 신규 고객 유입 부분에서도 두드러진 결과를 얻을 수 있었다.

신한카드에서는 상품개발 시 빅데이터를 활용하였다. 고객의 카드 사용실적을 분석하여 고객별 소비패턴 및 선호 트렌드를 파악하여 남녀 각각 9개의 고객군으로 클러스터링한 후, 각 그룹별 최적화된 코드나인(Code 9) 카드 시리즈를 출시했다. 이 상품은 최근 500만매를 돌파했고, 기존의 주력 카드보다도 평균 10%이상 이용률이 높다. 상품 개발 시 빅데이터를 활용한 성공적인 사례라고 업계에서는 평하고 있다.

출처: 삼성 SDS 인사이트리포트 "빅데이터 트렌드와 국내외 성공사례

은행 및 보험사

JP모건체이스(JP Morgan Chase)는 직원의 인터넷 사용 기록뿐만 아니라 개인정보인 이메일과 전화통화 기록까지 분석해 비리 협의를 포착하는데 빅데이터를 적용하고 있다. 또한, 은행이 담보로 잡은 부동산을 적절한 값에 매각하기 위한 최적의 가격 결정 모델을 구할 때도 사용하였다. 부동산 시장 상황을 지역별로 분석해 팔릴 만한 가격을 산정한다면 채무자가 지급불능에 빠지기 전에 부동산을 매각할 수 있어 사회적 손실도 줄일 수 있다.

미국의 보험회사인 프로그래시브(Progressive)사는 자동차에 부착된 기기가 전송하는 데이터를 바탕으로 고객의 운전 패턴을 분석하고 미래 사고 가능성을 예측하는데 빅데이터 기술을 활용하고 있다. 이를 통해 자동차 보험료를 산정하는 Pay as You Drive 시스템을 운영하고 있다. 즉, 상대적으로 덜 위험한 방법(속도, 운전습관)으로, 덜 위험한 시간대 및 지역에서 운전하는 고객일수록 적은 보험료를 낸다. 이는 고객들의 안전 운전을 유도하는데 도움을 준다.

다른 업종에 비해 국내 은행 및 보험사의 경우 빅데이터 활용사례가 많지 않은데, 주로 외부 공격의 차단이나 보험사기 적발 등에 활용하고 있다. 하나은행은 서버 침입을 막기 위해 로그 데이터를 수집/분석하는 시스템을 개발하여 악성코드 공격을 사전에 방지하는데 빅데이터를 활용하였으며 이로 인해 내부보안을 강화할 수 있었다.

삼성화재 경우 빅데이터를 활용하여 보험사기를 적발하고 있다. IFDS(Insurance Fraud Detection System)은 보험계약, 보험 정보 등 방대한 데이터를 활용하여 사기 고위험군을 자동 추출해서 현장조사 전문인력에게 알려주고 조사에 착수한다. 이 시스템으로 인해 허위 신고로 보상금을 받으려는 보험사기 건을 적발할 수 있었다.

핀테크

미국기업인 Lenddo는 신용평가 알고리즘을 개발할 때 온라인상 대출자의 평판에 대한 비정형 데이터를 추출하여 신용도를 평가한다. 즉, SNS 친구 중 연체자가 있거나 '자동차사고' 및 '실직' 같은 부정적인 단어가 많이 나오면 신용점수가 낮아진다. 개인이 아닌 소상공인경우 기업의 평판 및 영업 활성화 정도를 통해 대출 여부를 판단한다.

독일의 Kreditech사는 기존 은행거래정보 외에 페이스북, 이베이, 아마존에서의 행동 패턴을 반영하여 대출여부를 판단한다. 맞춤법을 틀리지 않는 대출자는 틀리는 대출자에 비해 덜 연체하는 특성을 가지고 있다. 따라서 맞춤법의 틀리는 정도를 신용평가 모델의 변수로 사용하고 있다.
또한, 대출정보 약관을 얼마나 꼼꼼히 읽었는지 여부도 변수로 넣었다. 이는 대출신청 서류를 상세히 보는 사람일수록 대출을 갚는 경향이 높기 때문이다. 흥미로운 결과로는 주기적으로 택배 기사가 방문하는 여부를 신용평가에 반영했다는 것이다. 이유는 주기적으로 온라인 쇼핑을 했다는 것은 일정한 소득이 있다고 추정할 수 있기 때문이다.

국내의 경우 상대적으로 핀테크 사업에서 빅데이터 활용사례를 찾기 어려웠다. 몇 안 되는 사례 중 하나는 국내 P2P(Peer to Peer:개인간) 대출 플랫폼 회사인 렌딧(LENDIT)이다. 이 회사는 대출자의 페이스북 정보 및 렌딧 웹사이트에서 투자설명서를 읽는 동작 패턴을 신용평가의 주요변수로 사용하였다.
예를 들면 최근에 벤처기업으로 이직하면서 증빙 소득이 내려간 대출 희망자의 소셜데이터를 분석하니 대출 희망자와 가족이 전문직에 종사하며 안정적으로 살고 있는 것을 확인할 수 있었다. 이 경우 소득 대비 상환여력 점수가 높아 더 나은 조건으로 대출을 승인했다고 한다.

국민건강지수 모니터링 시스템

빅데이터하면 구글의 독감예측시스템을 다들 기억할 것이다. 몇 년 전 구글은 독감관련 검색어를 기반으로 어느 지역에 독감이 많이 발생하는지 미국지도와 함께 알려주는 시스템을 개발하였다. 이는 빅데이터의 유명한 사례 중 하나로 꼽고 있다.
이후 좀더 발전된 시스템으로 미국스포츠의학학회(ACSM, American College of Sports Medicine)에서 도시별 미국 건강지수를 매해 분석하고 리포트하고 있다. 국민의 체력뿐만 아니라 영양정보를 고려하여 건강수준을 도시 별로 비교할 수 있도록 미국건강지수(American Fitness Index)를 빅데이터를 활용하여 개발하였고 이를 헬스케어 분야에서 활용할 수 있도록 공개하고 있다.

이와 비슷하게 국민건강보험공단에서는 국민건강 주의 알람 시스템을 운영하고 있다. 주 질병인 감기, 눈병, 식중독, 천식, 피부염을 선정하여 알람 서비스를 제공하고 있다. 질병 별로 지역과 연령을 구분해 관심, 주의, 경계, 위험 4단계로 위험도를 표시하여 사전에 주의사항을 안내하고 사전 예방 캠페인을 진행하고 있다. 이는 기간별 진료데이터 및 SNS상의 키워드 빈도수를 근거로 질병을 예측하는 시스템이다.

더 나아가 올해는 국민의 건강수준을 분석하여 제공하는 과제를 시행하려고 한다. 건강보험 청구 및 의약품 처방조제 등 방대한 보건의료 정보뿐만 아니라 기후정보를 융합하여 계절성 질병까지 예측하는 시스템을 개발 계획 중에 있다. 이는 국가차원에서 질병위험도를 예측하여 잠재적인 문제를 사전에 파악 예방하려는 노력으로써 방대한 데이터를 활용한 국민건강 예방시스템이라 할 수 있다.

IBM 왓슨(Watson) 의료분야 활용

사람의 말을 이해하고 대답할 수 있는 IBM의 인공지능 슈퍼컴퓨터인 왓슨(Watson)은 방대한 의료데이터를 분석하여 환자를 진단하여 의사에게 치료법을 추천해준다. 수백만 건의 진단서, 환자기록, 의료서적 등의 방대한 데이터를 바탕으로 왓슨 컴퓨터는 순식간에 분석을 통해 확률이 가장 높은 병명과 성공 가능성이 높은 치료법을 동시에 의사에게 조언을 한다. 그럼으로써 의사마다 다른 판단을 내릴 수 있는 경우 판단의 오차를 크게 줄이고 객관성을 높일 수 있다.

실제적으로 의료계에서는 환자의 상태를 파악하고 치료법까지 찾는데 며칠씩 걸리는 경우가 많다.하지만 왓슨은 몇 분만에 찾을 수 있어서 치료를 빨리 시작할 수 있게 되었다. 최근 발표에 의하면 IBM은 MD앤더스 암센터를 포함한 유명 암센터와 협력하여 암 진단과 치료법에 대해 연구하였고, 연구 결과 특정 암 진단을 하기 위해 한 명의 의사가 160시간 이상 걸리는 결과를 왓슨은 수분 만에 결과를 냈고 정확도도 96%에 달한다고 공개했다. 또한, MRI나 CT같은 영상정보를 판독하고 진단하는 기술도 많이 발달하였다고 발표했다.

부정적인 시각도 있다. 과연 왓슨이 의사를 대신할 수 있을지 많은 사람들이 의문을 갖고 있다. 저자는 왓슨의 의견을 바탕으로 최종 결정은 의사가 내려야 된다고 생각한다. 즉, 왓슨의 분석 결과는 단지 참고사항으로만 활용되어져야 한다.

Skill for Data Scientists

The ability to **take** data — to be able to **understand** it, to **process** it, to **extract** value from it, to **visualize** it, to **communicate** it — that's going to be a hugely i mportant skill in the next decades not only at the professional level but even at t he educational level for elementary school kids, for high school kids, for college kids. Because now we really do have essentially free and ubiquitous data."

- *Hal Varian, chief economist at Google and UC Berkeley professor of information sciences, business, and economics* [3]

Data Science Process

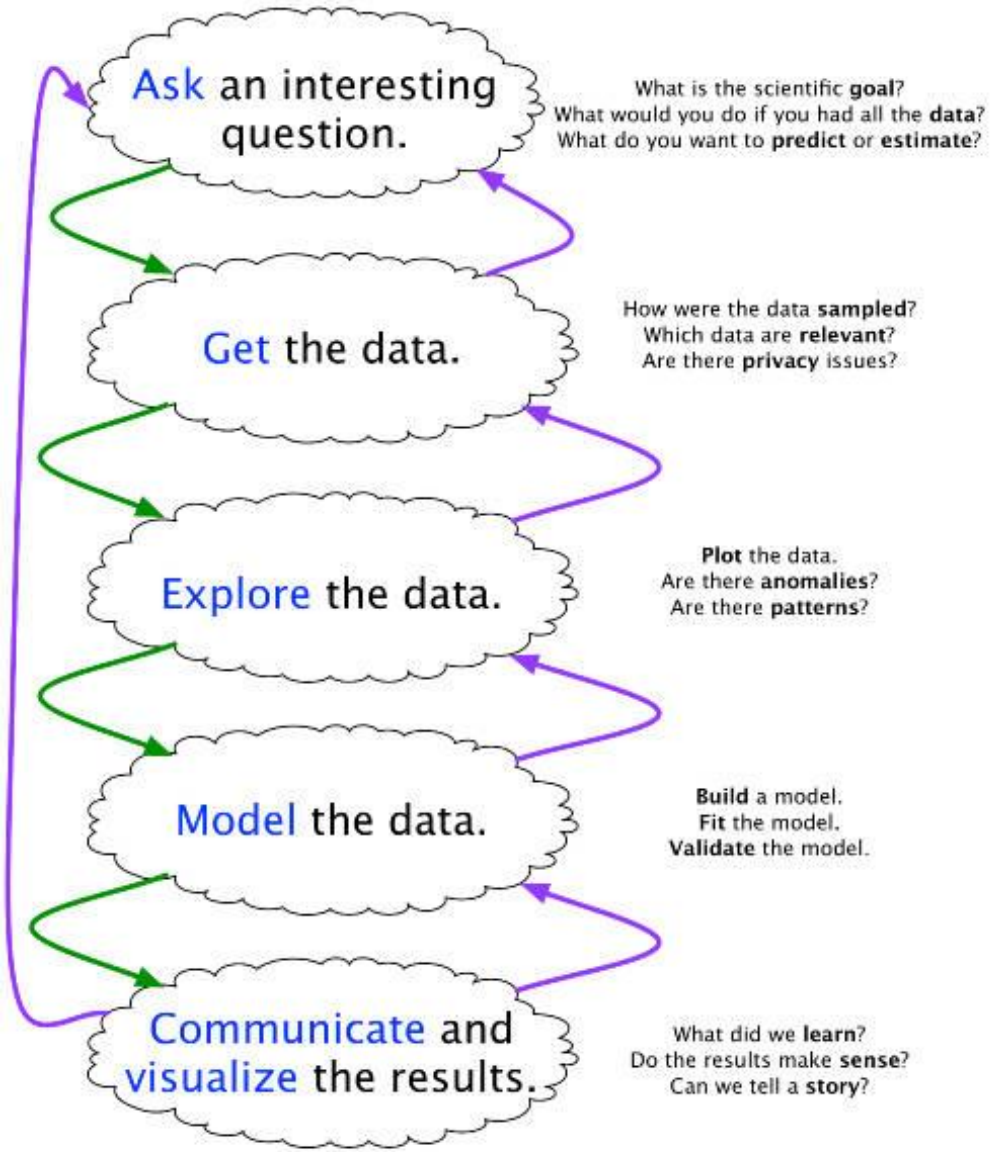

Joe Blitzstein and Hanspeter Pfister, created for the Harvard data science course http://cs109.org/.

Stage 1: Ask A Question
- Skills: science, domain expertise, curiosity
- Tools: your brain, talking to experts, experience

Stage 2: Get the Data
- Skills: web scraping, data cleaning, querying databases, CS stuff
- Tools: python, pandas

Stage 3: Explore the Data
- Skills: Get to know data, develop hypotheses, patterns? anomalies?
- Tools: matplotlib, numpy, scipy, pandas

Stage 4: Model the Data
- Skills: regression, machine learning, validation, big data
- Tools: scikits learn, pandas, mrjob, mapreduce

Stage 5: Communicate the Data
- Skills: presentation, speaking, visuals, writing
- Tools: matplotlib, adobe illustrator, powerpoint/keynote