3장. 예측 모델링(Predictive Modeling)

예측 모델링(Predictive Modeling)

- **모델**
  - 어떤 목적을 달성하기 위해 실세계를 단순하게 표현한 것
- **예측모델**
  - 데이터과학에서 예측 모델은 우리가 관심을 갖는 타켓 변수값(혹은 반응변수, 종속 변수)을 예측하는 공식
  - 공식은 수학공식이 될 수도 있고 어떤 규칙을 설명하는 논리적인 문장이 될 수도 있고 혹은 두 형태의 혼합이기도 함
  - 분류 모델(classification model)
    - 타켓 변수가 범주형 값(categorical value)을 예측 할 때 (예, 이진 분류 yes or no)
  - 회귀 모델(regression model)
    - 타켓 변수가 수치형 값(numerical value)을 예측할 때
- **설명모델**
  - 값을 추정하기 위한 것이 아니라 어떤 현상이나 절차를 전체적으로 알기 쉽게 설명하기 위함인 모델
  - 하나의 모델을 예측 및 설명에 모두 사용 가능 —> 차이는 중요하지 않음

감독 세분화(Supervised Segmentation)

- **관심있는 어떤 성질(혹은 속성)을 기준으로 전체 데이터를 그룹으로 나누는 예측모델링의 대표적인 방법**
  - 계약 만료 후에 해지할 가능성이 있는 고객은 누구인가?
  - 어떤 고객이 지불을 연체할 것인가? (전화요금이나 신용카드 사용금액을 지불하지 않는 대손상각Write-off) 등
  - 타켓변수 값을 예측하는데 주요한 영향을 미치는 속성을 찾아내는 일이 매우 중요
  - 타켓변수를 기준으로 전체 데이터를 유사한 값을 가진 세크먼트로 분할하는 방법
  - "뉴욕시에 거주하는 중년 전문직 종사자의 평균 이탈률이 5%이다."
    - 뉴욕시에 거주하는 중년 전문직 종사자 —> 세그먼트(세그먼트를 구분짓는 속성은 거주지, 나이, 직업!!)
    - 이탈률 5% —> 세그먼트의 타켓값 예측

대손상각(Write-Off) : 경영 대출금, 받을 어음, 외상 매출금 따위의 수취 채권 가운데 회수 불가능한 금액을 영업 손실을 처리하는 행위

감독 세분화

- **고객 이탈 문제의 경우, "이탈 성향을 예측하는데 가장 좋은 세그먼트의 속성들이 무엇인가?"**
  - 즉, 어떤 변수(속성, 특징, 혹은 독립변수, 설명변수)가 타켓변수(종속변수 혹은 반응변수)에 대한 중요한 정보를 담고 있는지 어떻게 판단할 수 있을까?
- **정보를 가장 많이 전달하는 속성을 선택하는 방법**
  - 전문직 종사자, 나이, 거주지, 소득, 고객 센터에 항의한 횟수, 평균 사용 요금 같은 변수 중 어떤 변수가 고객이 서비스를 해지할지 여부를 알려주는 가장 중요한 속성인가 ?
  - 데이터의 속성들이 너무 많을 때는 정보를 가장 잘 전달하는 속성들을 골라내는 것이 상당히 중요 —> 데이터 셋의 크기도 줄여주고 예측모델의 정확도도 향상 시킴

HANYANG UNIVERSITY

정보를 가장 많이 포함하는 속성(Informative Attributes) (1/2)

- 사례가 많을 때 정보를 가장 많이 포함하는 속성을 어떻게 골라내서 전체 데이터를 분할(segmentation)할 수 있을까?
- 예제1 : 대손 상각 여부를 예측할 수 있는 속성 선택하기

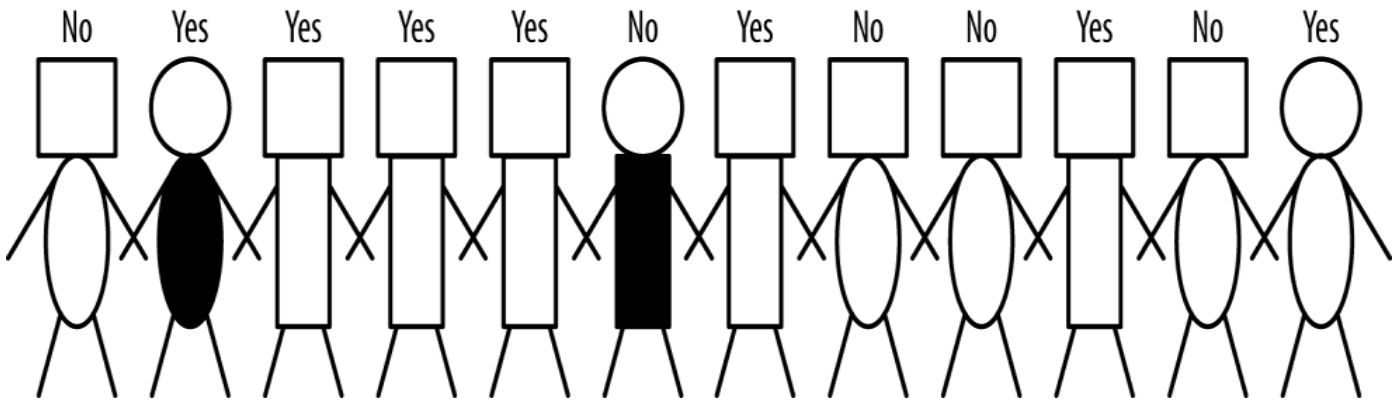

- 속성
  - HEAD-SHAPE(머리 모양): 사각형, 동그라미
  - BODY-SAHPE(몸 모양): 직사각형, 타원형
  - BODY-COLOR(몸 색): 회색, 흰색
- 타켓변수
  - WRITE-OFF(대손상각 여부): yes, no

정보를 가장 많이 포함하는 속성 (2/2)

- **고려해야 할 사항**
  1. 그룹을 완전히 분리하는 속성은 없다. 어떤 세그먼트는 순수하다(동일한 타켓값만 존재할 경우)고 해도 다른 세그먼트는 그렇지 않기 때문이다. 예제1에서 두번째 사람이 없다고 가정하자. 몸색이 회색인 세그먼트는 순수하지만 하얀색인 세그먼트는 순수하지 않다.
  2. 1번에서 몸색이 회색인 조건은 객체 하나만 세그먼트에 들어가므로 순수하다. 그러나 이 분할 방법이 순도를 높이는 다른 분할방법보다 좋다고 할 수 있을까?
  3. 속성값이 2개만 있는 것도 아니고 2개 세그먼트로 나누는 속성도 있지만 3개 이상의 세그먼트로 나누는 속성도 있을 수 있다. 이런 경우는 어떻게 비교할 것인가?
  4. 어떤 속성은 수치값을 갖는다. 각 수치값마다 세그먼트를 만들어야 할까? 어떤게 수치값을 나눌 것인가?
- **분할기준이 필요**
  - 정보이론(information theory)
  - 정보량(quantity of information) 및 엔트로피(entropy)

정보이론: 엔트로피

- **정보이론(information theory)**
  - 2차 세계대전 당시 클로드 새넌(Claude Shanon)에 의해 발전
  - 불완전한 통신 채널을 통해 정보를 전송할 때 정보 전송의 효율을 최대화하기 이론(엔트로피)을 개발
- **정보량(quantity of information, I)**
  - 한 사건에서 기대되는 정보량을 어떻게 나타낼 수 있을지를 생각해 보자
  - 정보량을 수량화하기 위하여 확률(P)과 정보량(I)을 다음의 두 확률 조건의 관점에서 살펴보자
    - 중요성(significance) : 어떤 사건이 일어날 가능성이 작으면 작을수록 그 사건은 더 많은 정보를 지닌다. (양치기 소년)
      - $P(X_1) > P(x_2) \Rightarrow I(x_1) < I(x_2)$
    - 가법성(additivity): 만일 x1, x2가 독립적인 사건이라면 다음을 만족해야 한다.
      - $I(x_1 x_2) = I(x_1) + I(x_2)$
  - 중요성 조건은 어떤 사건의 확률이 높을수록 이 사건으로 알려지는 정보량은 적어짐을 의미. 따라서 정보량은 확률값을 역으로 취해서 얻을 수 있음

$$I(x) = 1/P(x)$$

HANYANG UNIVERSITY

엔트로피

- **확률과 정보량의 관계1**
  - $P(x_1) = \frac{1}{2}, I(x_1) = \frac{1}{1/2} = 2$
  - $P(x_2) = \frac{1}{4}, I(x_1) = \frac{1}{1/4} = 4$
  - 만일 두 사건이 서로 독립적이라면,
    - $P(x_1 x_2) = P(x_1) \times P(x_2) = \frac{1}{2} \times \frac{1}{4} = \frac{1}{8}$
    - $I(x_1 x_2) = \frac{1}{P(x_1 x_2)} = 8$
  - 그러나, 가법성에 따라
    - $I(x_1 x_2) = I(x_1) + I(x_2) = 2 + 4 = 6$
  - 따라서, 가법성의 조건이 충족되지 못한다.
- **<u>정보량을 단순히 확률의 역으로 취하는 것은 바람직하지 못함</u>**
  - 두 독립 사건의 확률값은 곱으로 이루어지지만, 두 독립된 사건이 결합된 정보량은 더해져야만 한다. 정보의 가법성을 위해서 곱이 아닌 더하기가 필요함
  - 따라서, 로그함수(log)를 도입하게 된다.

$$\log(x_1 x_2) = \log x_1 + \log x_2$$

HANYANG UNIVERSITY

엔트로피

- **결국, 정보량은 다음과 같이 계산되어야 한다.**

$$I(x) = \log\frac{1}{P(x)} = -\log P(x)$$

- **확률과 정보량 관계2**
  - $P(x_1) = \frac{1}{2}, I(x_1) = -\log\frac{1}{2} = \log 2 = 1$
  - $P(x_1) = \frac{1}{4}, I(x_1) = -\log\frac{1}{4} = \log 4 = 2$
  - $P(X_1) > P(x_2) \Rightarrow I(x_1) < I(x_2)$ 인 중요성 조건을 만족한다. 또,
    - $P(x_1 x_2) = P(x_1) \times P(x_2) = \frac{1}{8} \Rightarrow I(x_1 x_2) = -\log(\frac{1}{8}) = 3$
    - $I(x_1 x_2) = I(x_1) + I(x_2) = 1 + 2 = 3$
  - 가법성의 조건도 만족하게 된다.

HANYANG UNIVERSITY

엔트로피

- **엔트로피(entropy)**
  - 확률변수 X의 표본 공간에서 나타나는 모든 사건들의 정보량의 평균적인 기대값을 엔토로피라 하고 보통 H로 표시
  - 일반적으로 엔트로피는 어떤 확률변수가 지니는 평균적인 불확실성(uncertainty) 혹은 무질서를 측정하는데 이용됨

$$H(X) = -\sum_{x \in X} P(x) \log_2 P(x)$$

  - 결국, 엔트로피는 한 확률변수에서 나타나는 개발적인 사건의 확률과 그 정보량을 곱하고 이를 다시 모두 더해서 얻어짐
  - 정보이론에서 엔트로피는 최적의 코딩을 위해 필요한 비트 최소 비트수를 의미하기도 함
    - 어떤 정보도 없는 상황에서 1번부터 8번까지 8마리 말이 함께 참가하는 경마에서 매 경기마다 우승하는 말의 번호를 확률변수 X라 하고, 이 확률변수의 엔트로피를 계산하면,

$$H(X) = -\sum_{x \in 1}^{8} \frac{1}{8} \log_2 \frac{1}{8} = -\log \frac{1}{8} = 3$$

엔트로피 – 예제1

- **계층(class) 값이 두개인 집합에서 p(+) 함수에 따른 엔트로피**
  - +와 -, 두 개의 값을 갖는 10개의 객체가 담고 있는 집합들의 엔트로피 증가(감소) 그래프
  - 집합 항목의 값들이 모두 -이거나 +인 경우 엔트로피는 0
  - +가 5개, -가 5개인 경우 P(+) = 1/2, p(-) = 1/2 이므로 엔트로피는 1

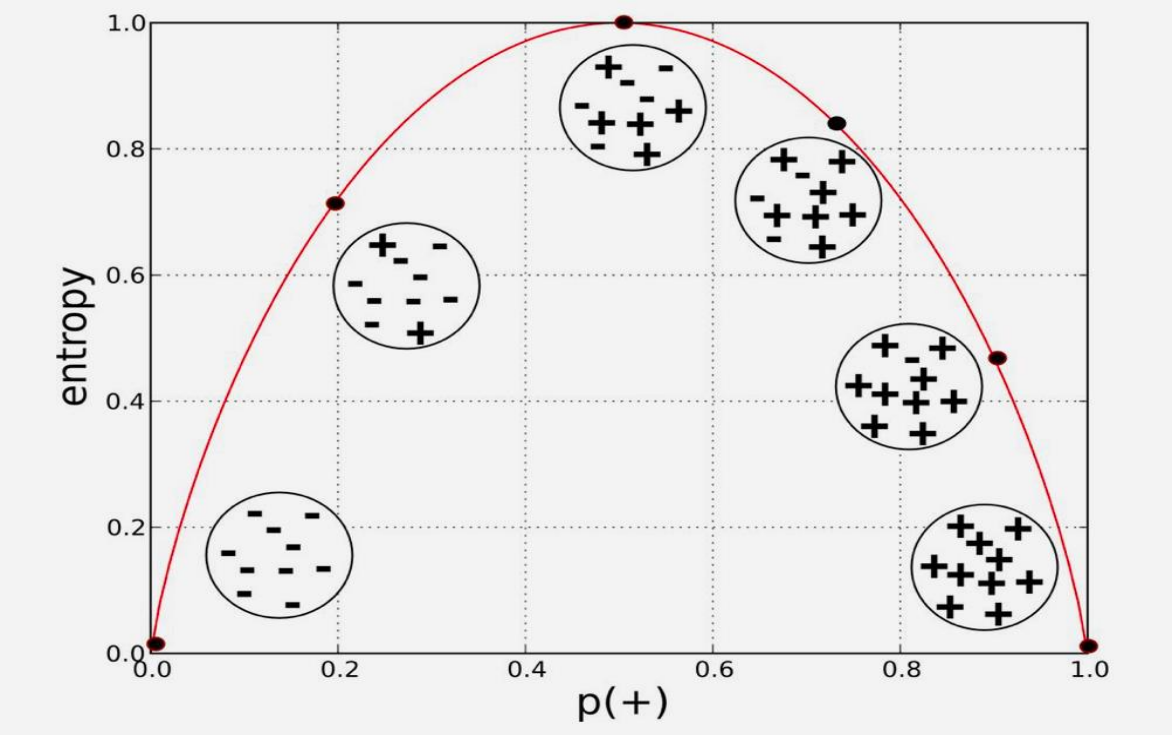

엔트로피 – 예제2

- **총 10명의 고객 중 정상상환 고객이 7명이고, 대손상각 고객이 3명인 경우 엔트로피**
  - p(정상상환) = 7/10 = 0.7
  - p(대손상각) = 3/10 = 0.3
  - entropy(S) = $-[0.7 \times \log_2(0.7) + 0.3 \times \log_2(0.3)] \approx 0.88$
- **어떤 속성이 얼마나 많은 정보를 제공하는가?**
  - 속성은 전체 객체들을 여러 부분 집합으로 분할하고, 엔트로피는 어떤 부분집합이 얼마나 순수하지 않은지를 알려줌
  - 결국, 어떤 속성에 따라 분류하면 전체 그룹의 엔트로피가 증가(감소)되는지 측정할 수 있음
- **정보증가량(IG: information gain)**
  - 새로 추가된 정보에 의한 엔트로피의 변화량
  - 분할 기준이 되는 속성이 k개의 값을 가질 수 있다고 가정
    - 원래의 집합: 부모집합
    - k개로 분할된 집합: 자식집합

$$IG(parent, children) = H(parent) - \sum_{i=1}^{k} p(c_i) \times H(c_i)$$

엔트로피 – 예제3

- 5만불을 기준으로 잔고(Balance) 속성값에 대해 대손상각 여부를 분할하는 경우

Attributes

Target attribute

Name	Balance	Age	Employed	Write-off
Mike	$200,000	42	no	yes
Mary	$35,000	33	yes	no
Claudio	$115,000	40	no	no
Robert	$29,000	23	yes	yes
Dora	$72,000	31	no	no

This is one row (example).
Feature vector is: **<Claudio,115000,40,no>**
Class label (value of Target attribute) is **no**

1. 5만불을 기준으로 잔고(Balance) 속성값에 대해 대손상각 여부를 분할하는 경우

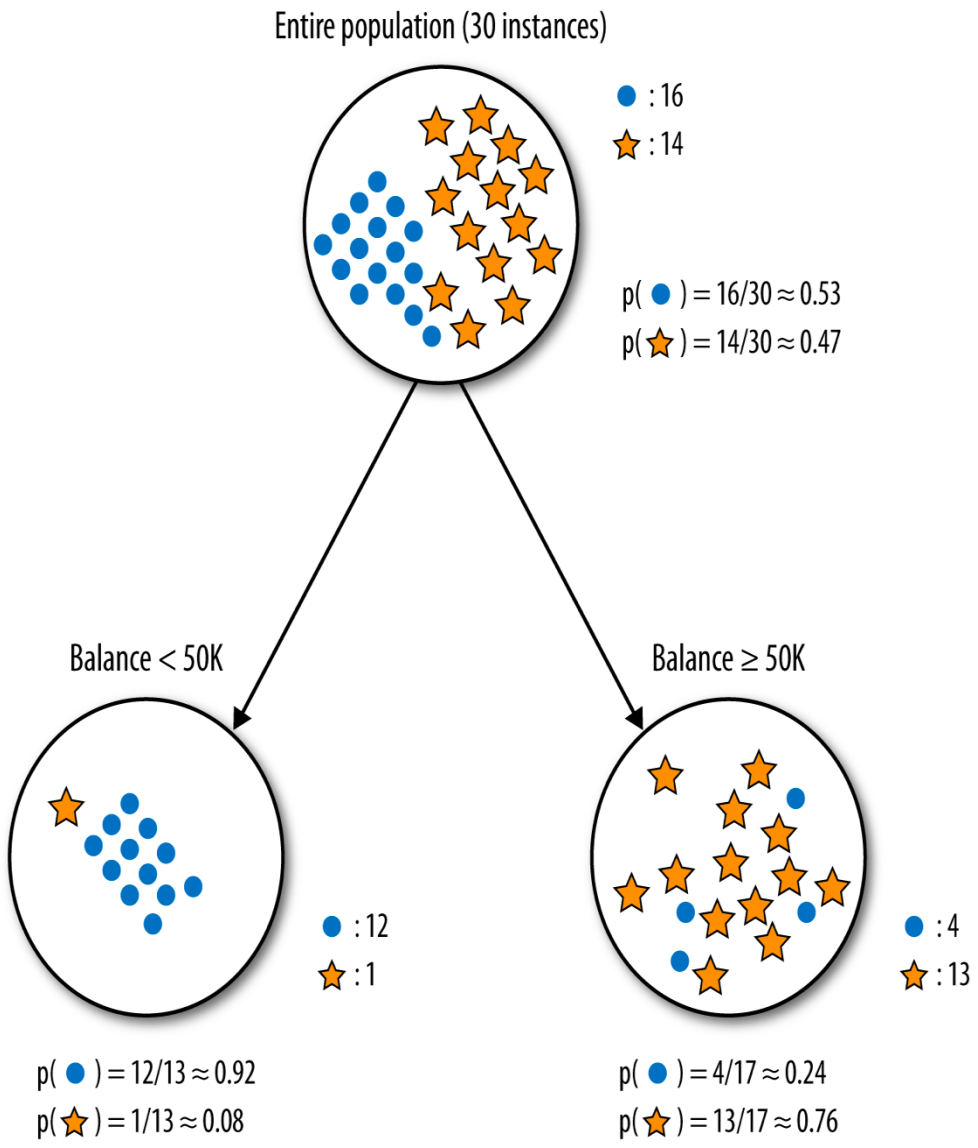

$$
\begin{aligned}
entropy(parent) &= -[p(\bullet) \times \log_2 p(\bullet) + p(\star) \times \log_2 p(\star)] \\
&\approx -[0.53 \times -0.9 + 0.47 \times -1.1] \\
&\approx 0.99 \quad \text{(very impure)}
\end{aligned}
$$

The entropy of the *left* child is:

$$
\begin{aligned}
entropy(Balance < 50K) &= -[p(\bullet) \times \log_2 p(\bullet) + p(\star) \times \log_2 p(\star)] \\
&\approx -[0.92 \times (-0.12) + 0.08 \times (-3.7)] \\
&\approx 0.39
\end{aligned}
$$

The entropy of the *right* child is:

$$
\begin{aligned}
entropy(Balance \geq 50K) &= -[p(\bullet) \times \log_2 p(\bullet) + p(\star) \times \log_2 p(\star)] \\
&\approx -[0.24 \times (-2.1) + 0.76 \times (-0.39)] \\
&\approx 0.79
\end{aligned}
$$

$$
\begin{aligned}
IG &= entropy(parent) - [p(Balance < 50K) \times entropy(Balance < 50K) \\
&\quad + p(Balance \geq 50K) \times entropy(Balance \geq 50K)] \\
&\approx 0.99 - [0.43 \times 0.39 + 0.57 \times 0.79] \\
&\approx 0.37
\end{aligned}
$$

2. 속성값이 3개인 거주 속성(Residence) 속성을 기준으로 분할할 경우

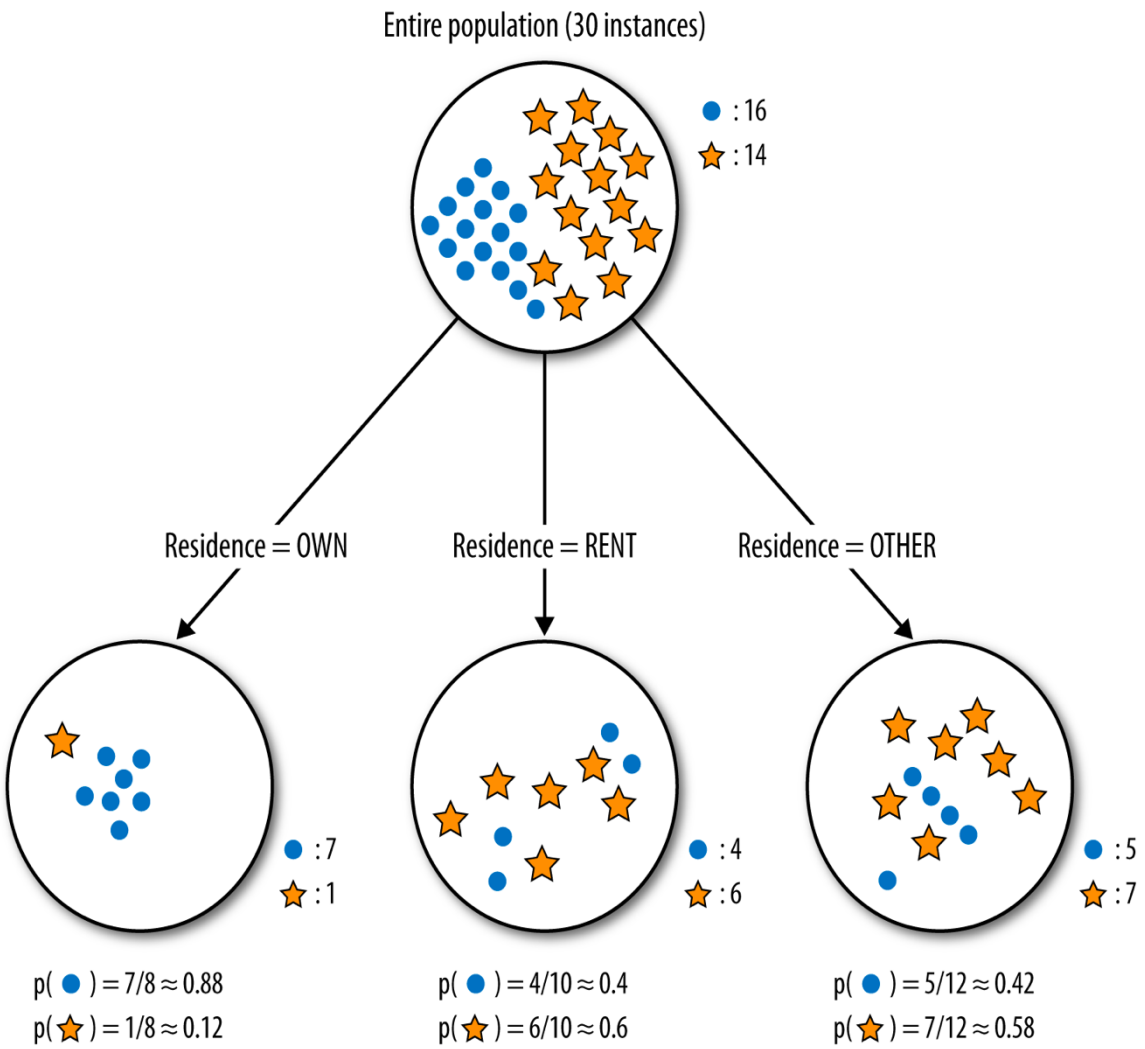

$$entropy(parent) \approx 0.99$$

$$entropy(\text{Residence=OWN}) \approx 0.54$$

$$entropy(\text{Residence=RENT}) \approx 0.97$$

$$entropy(\text{Residence=OTHER}) \approx 0.98$$

$$IG \approx 0.13$$

- **[예제3]에 대한 고찰**
  - Balance 속성이 Residence 속성보다 더 많은 정보를 제공한다. 결국, 대손상각 여부를 결정하는데 더 중요한 속성
  - 너무 다양한 값을 가질 수 있는 속성에 대해서 정보증가량 방법을 이용하는 경우 과적합 문제가 발생할 수 있어 예측에 적합하지 않을 수 있다.
  - 수치형 변수는 분할점을 하나 또는 여러 개 선정해서 분할할 수 있고 분할된 범위들을 범주형 속성으로 처리할 수 있다(예, Balance나 Income 속성)
  - 수치형 속성에 대해서 이런 식으로 범주화해서 정보증가량 방법을 사용할 수 있지만 수치형 속성을 나눌 분할점을 선택하는 방법에 대한 문제를 먼저 해결해야 한다. 개념적으로 타당성 있는 분할점을 모두 시도해본 후에 정보량이 가장 많이 증가하는 분할점을 사용해 볼 수도 있다.

회귀분석 문제의 감독 세분화

- **타켓 변수가 수치형인 문제는 어떻게 처리해야 할까?**
  - 엔트로피 기반의 정보 증가량은 각 세그먼트에 속성을 분배하는 밥법을 사용하기 때문에 수치형 타켓 변수를 예측하는데는 적합하지 않음
  - 수치형 값의 불순도를 측정하는 방법에는 분산이 유용
    - 집합 안에 모든 항목들이 동일한 타켓값을 갖는다면 분산은 0
    - 집합 안에 수치형 타켓값이 상당히 다르다면 큰 분산값
  - 부모집합과 자식집합에서 분산을 줄이는 방법을 찾다보면 정보 증가량과 비슷한 개념을 찾을 수 있음
  - 수치형 타켓값을 가장 잘 세분화하려면 가중치 평균의 분산이 가장 많이 줄어들게 만드는 속성을 선택하면 됨
  - 결국, 타켓 변수와 연관이 깊은 속성 즉, 타켓을 잘 예측할 수 있는 변수를 찾는 과정

연습문제1

- **데이터셋 설명**
  - 이 데이터 셋에는 주름버섯과 및 갓버섯과에 속하는 갓이 달린 23종의 버섯에 대한 가상의 설명을 담고 있다. 각각의 종은 식용가, 식용불가(독성)로 구분된다. 버섯의 식용성을 판단하는 규칙은 없다.
  - http://archive.ics.uci.edu/ml/datasets/Mushroom
- **질문**
  - 어느 속성이 식용버섯(ediable)과 독성버섯을 구분하는데 가장 유용한가?
- **참고**
  - 엔트로피, 정보증가량 등 이용하기
  - 히스토그램을 그려서 시각적 보여주기
  - 파이썬 코드 제출!!

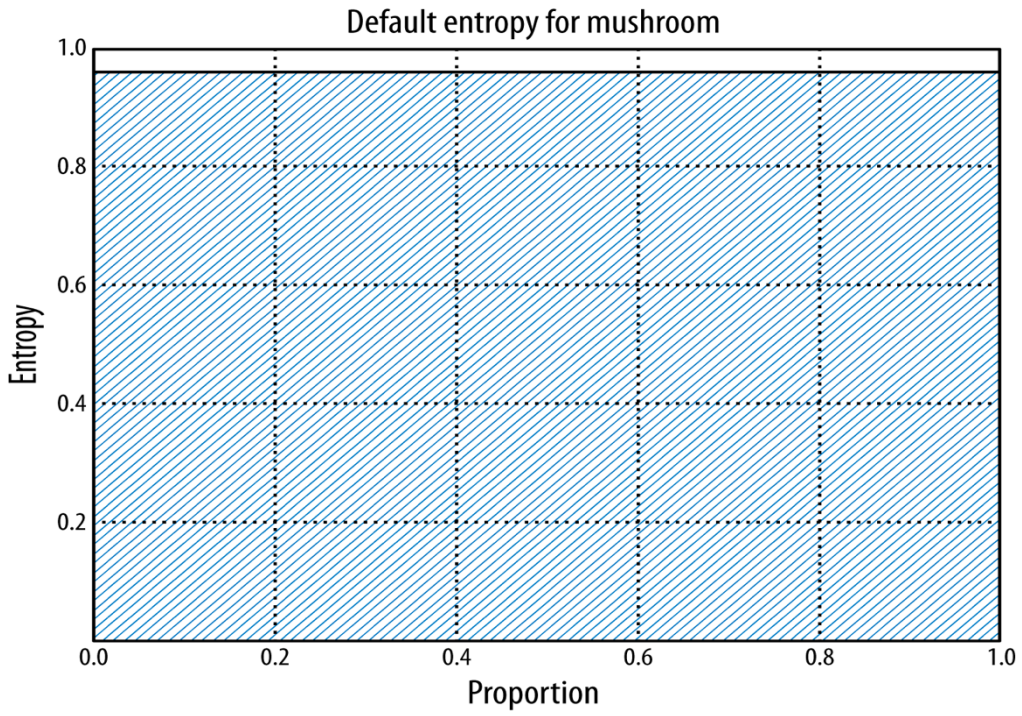

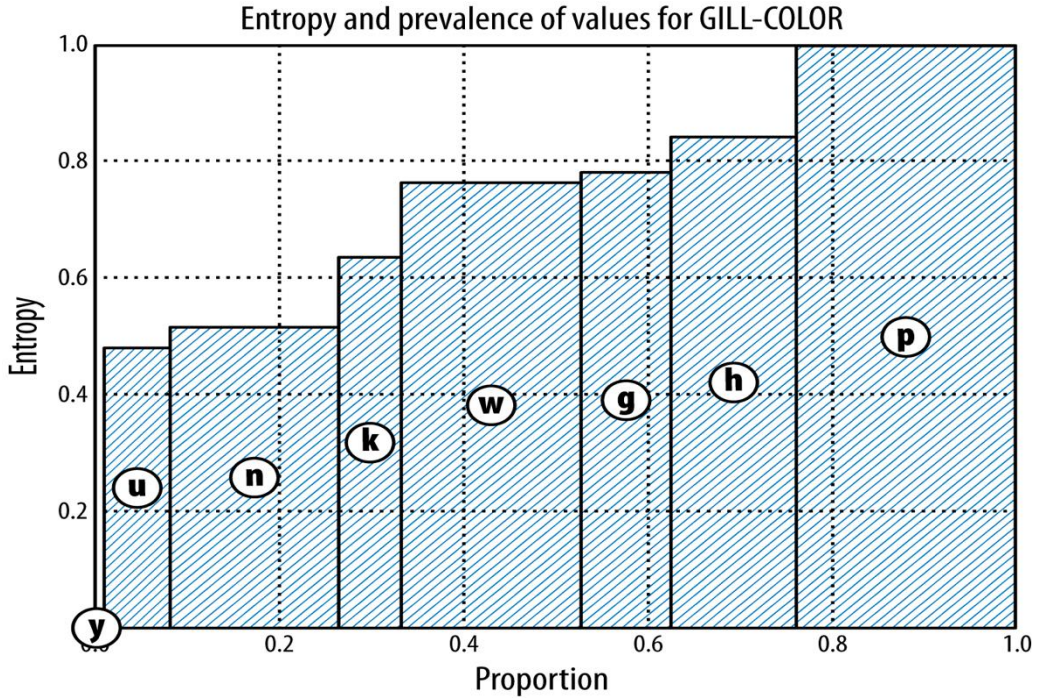

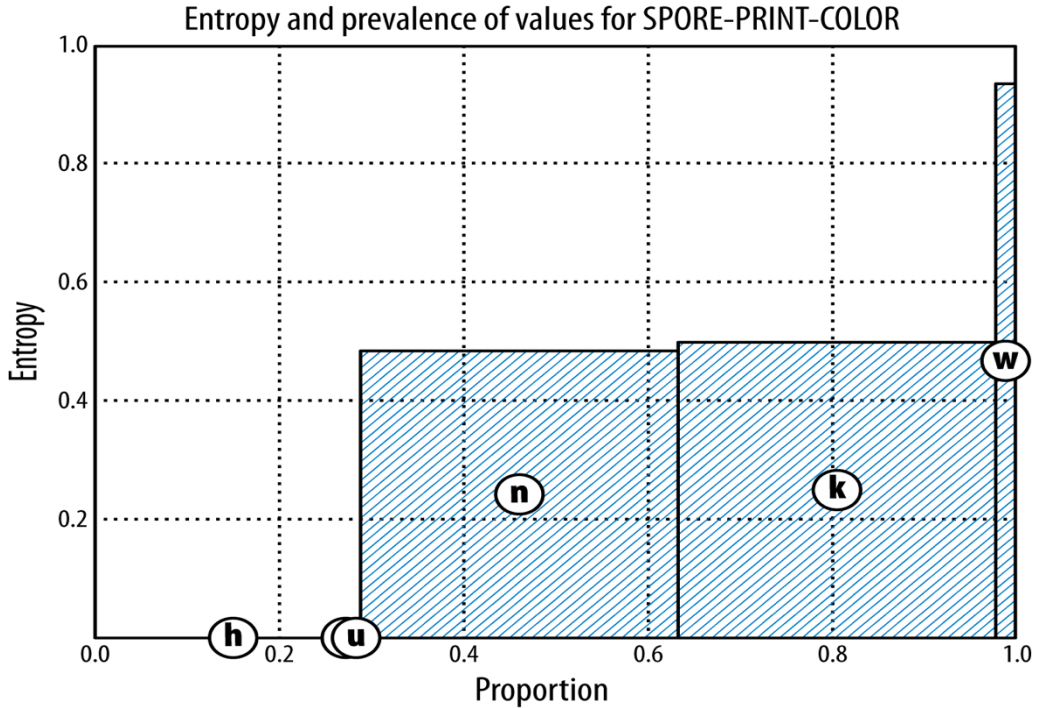

시각화 관점에서,
부모(분화전 전체그룹의 엔트로피) 엔트로피 히스토그램의 전체 면적과 자식 그룹들의 엔트로피 히스토그램 면접의 합의 차이가 가장 큰 경우가 정보량이 가장 증가한 경우

다변량(multivariate) 감독 세분화

- 속성을 여러 개 사용하여 감독 세분화 하는 과정

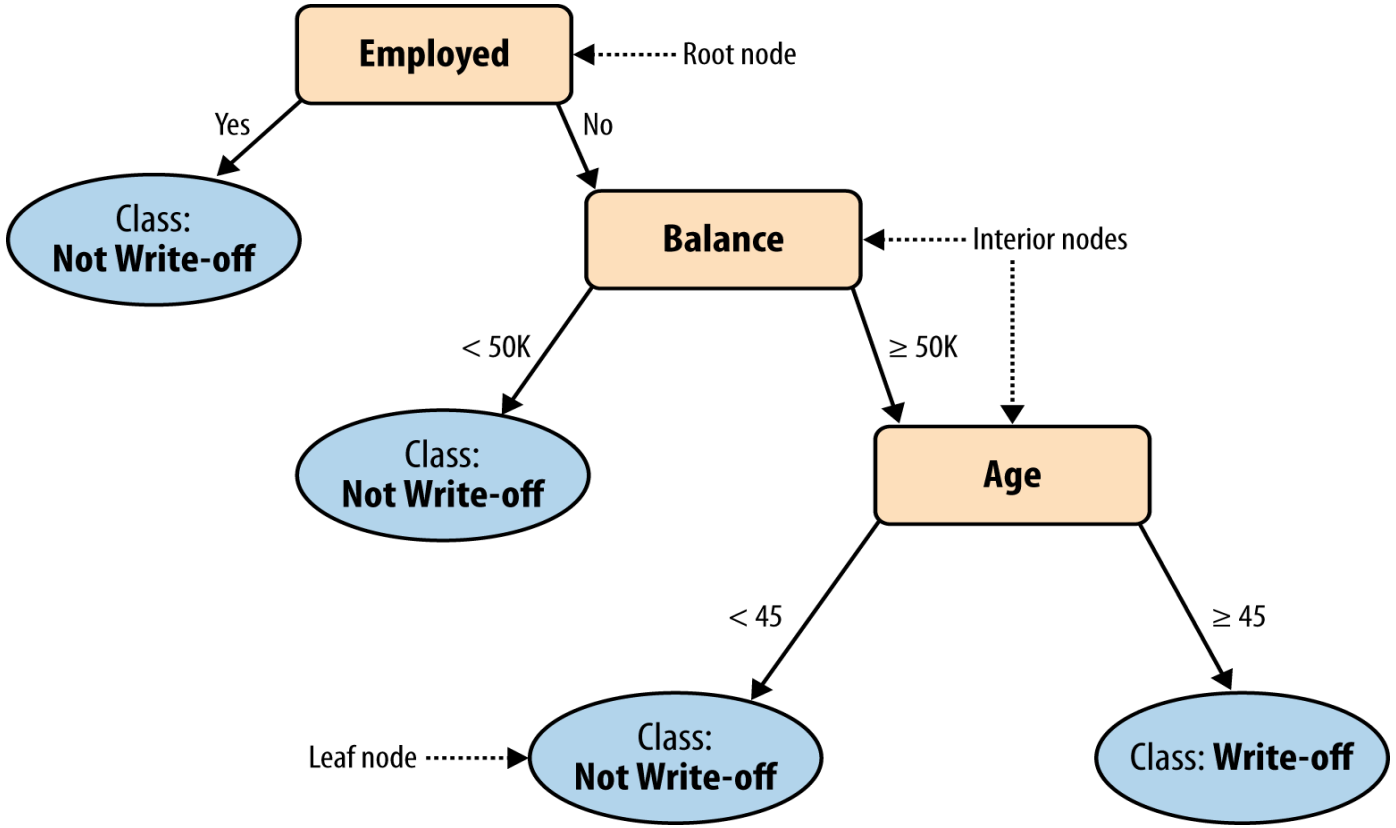

결정트리(Decision Tree)

- **감독세분화의 대표적인 알고리즘**
  - 데이터를 분류하거나 예측하기 위해 데이터 속성을 일정 기준으로 반복해서 분할하여 나무 구조 형태로 데이터를 세분화하는 지도학습 모델
  - 결정트리를 이용하면 어떻게 분류할지 모르는 데이터가 입력되었을 때 어떤 세그먼트로 분류할지를 예측할 수 있음
  - [예제2]에서 <Claudio, 115000, 40, no>가 입력되면 루트노드부터 시작해서 Employed=no이므로 우측 노드로 가고 Balance=$115,000이므로 다시 우측노드로 진행함. 마지막으로 Age=40이므로 좌측노드 "Not Write-off"으로 분류됨
- **구조**
  - 내부노드
    - 속성값에 따라 새로운 가지로 또 다른 내부노드로 분화하거나 단말노드를 가리킴
  - 단말노드
    - 하나의 세그먼트에 해당하고 단말노드까지 도착하는 동안 경로에 있는 값들은 세그먼트의 특성을 나타냄
      - 우측 제일 하단에 있는 세그먼트: 고용되지 않았고 은행잔고가 5만불보다 많고 연령이 45세 이상

결정트리 유도

■ **데이터로부터 결정트리를 만드는 방법**

- 기본적으로 분할정복(divide-and-conquer) 알고리즘
- 전체 데이터 세트에서 시작해서 속성을 기준으로 가장 순수한 하위 그룹으로 분할하는 변수를 찾음 : 정보증가량 이용
- 각 데이터의 부분집합에 대해서 데이터를 가장 잘 분할하는 속성을 찾아가는 과정을 반복적으로 적용

1.첫번째 분할: 몸의 모양에 따라 분류
(사격형, 타원형)

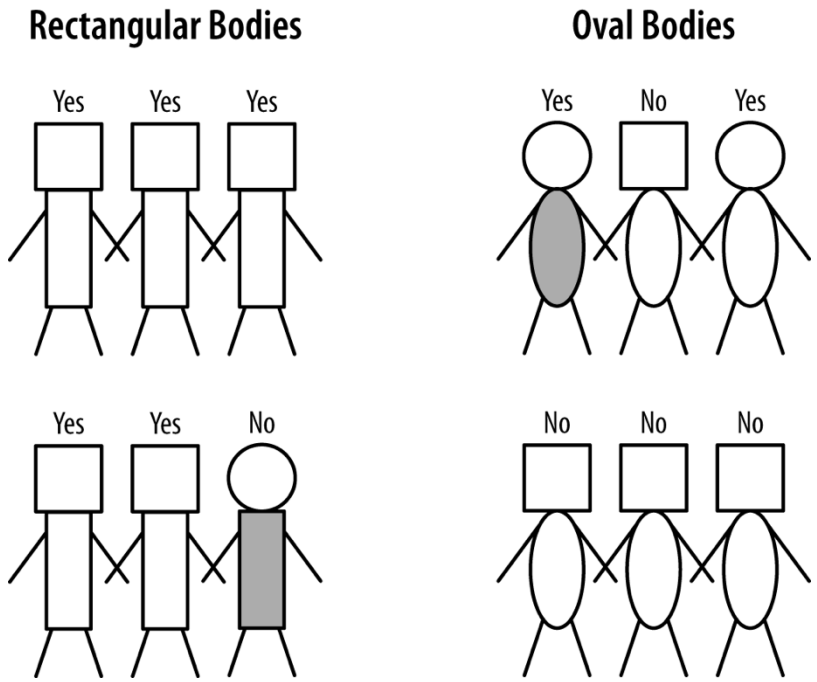

결정트리 유도

2.두번째 분할(사각형 몸통)
: 몸 색상

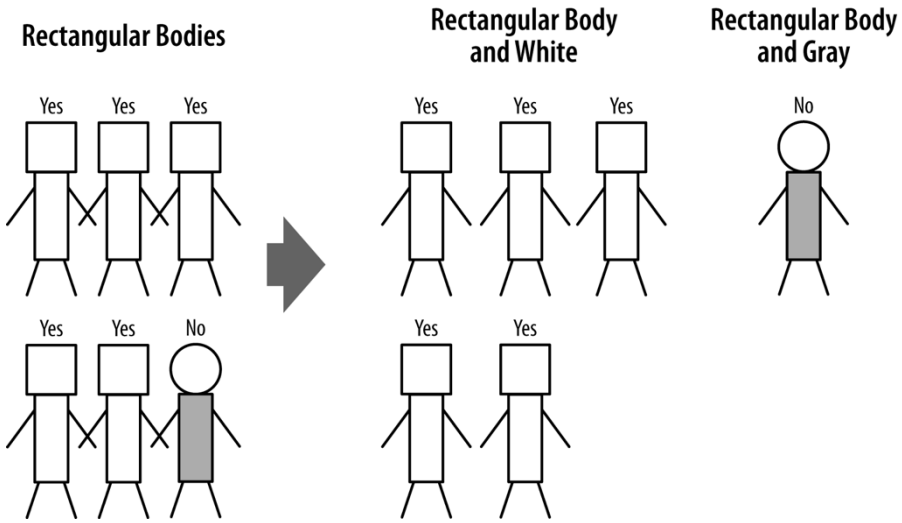

3.세번째 분할(타원형 몸통)
: 머리 모양

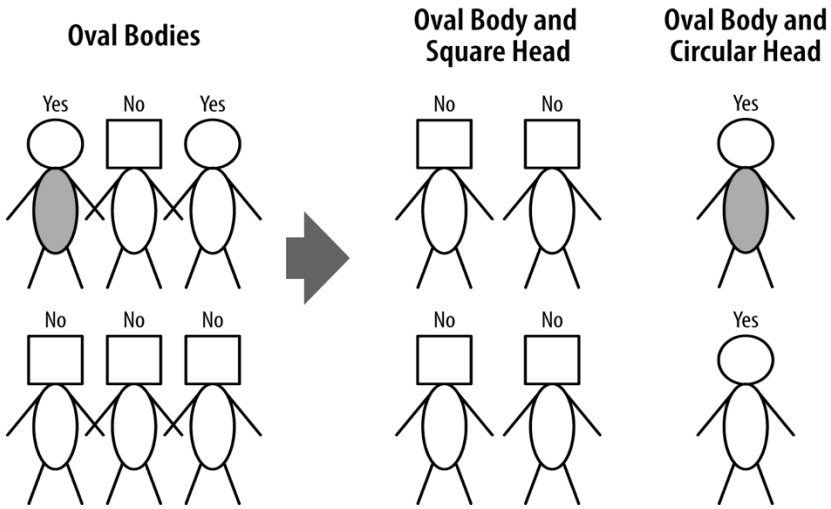

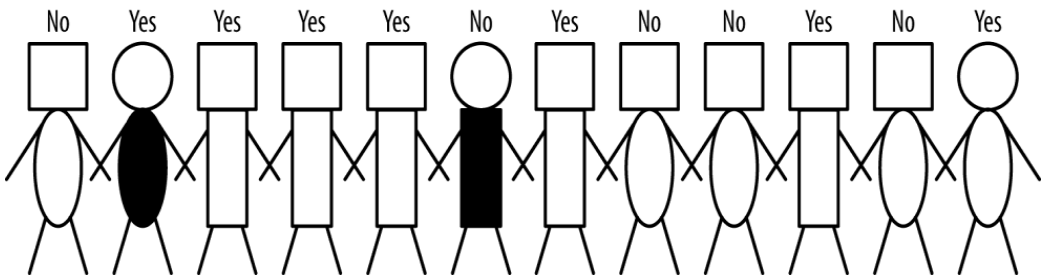

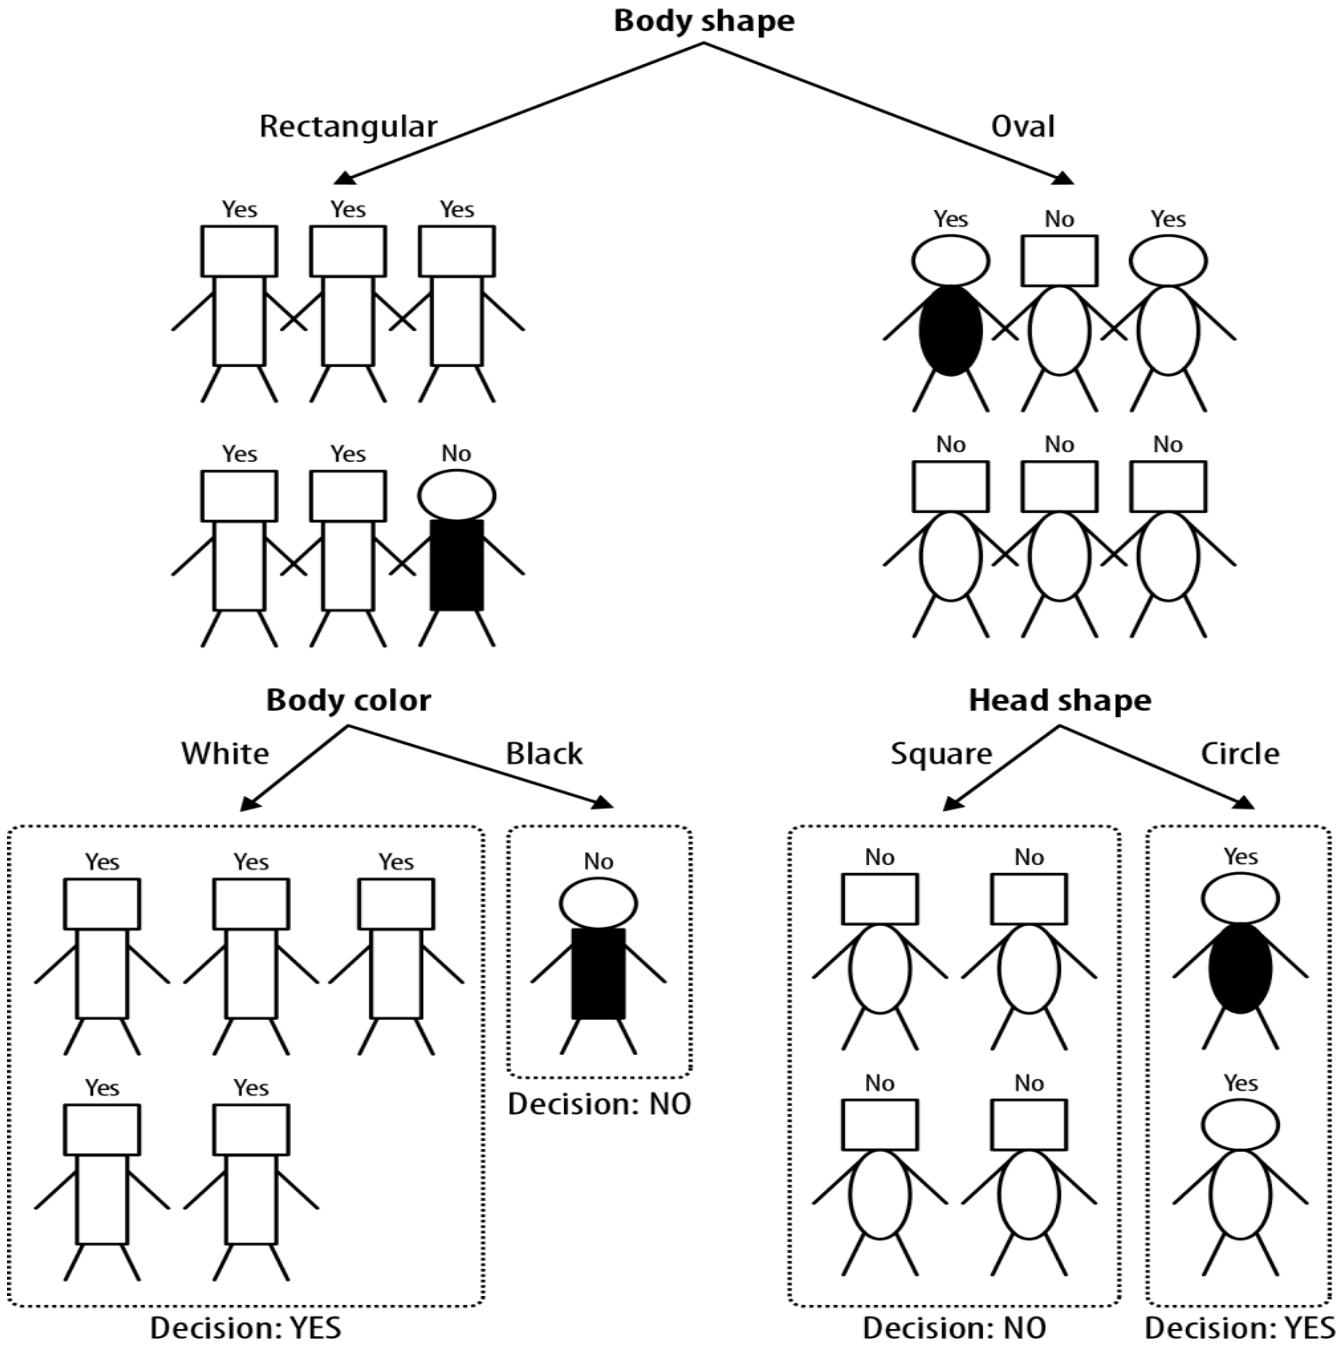

<결정트리 유도 과정>

1. 각 단계에서 현재 그룹을 타켓 변수 측면에서 가장 순수하게 분할할 수 있는 변수를 선택
2. 그런데, 언제 종료하지 ? 단순한 경우 노드가 순수해 지거나 더 이상 분해할 변수가 없을 때, 그러나 변수가 너무 많으면??

세분화 과정의 시각화

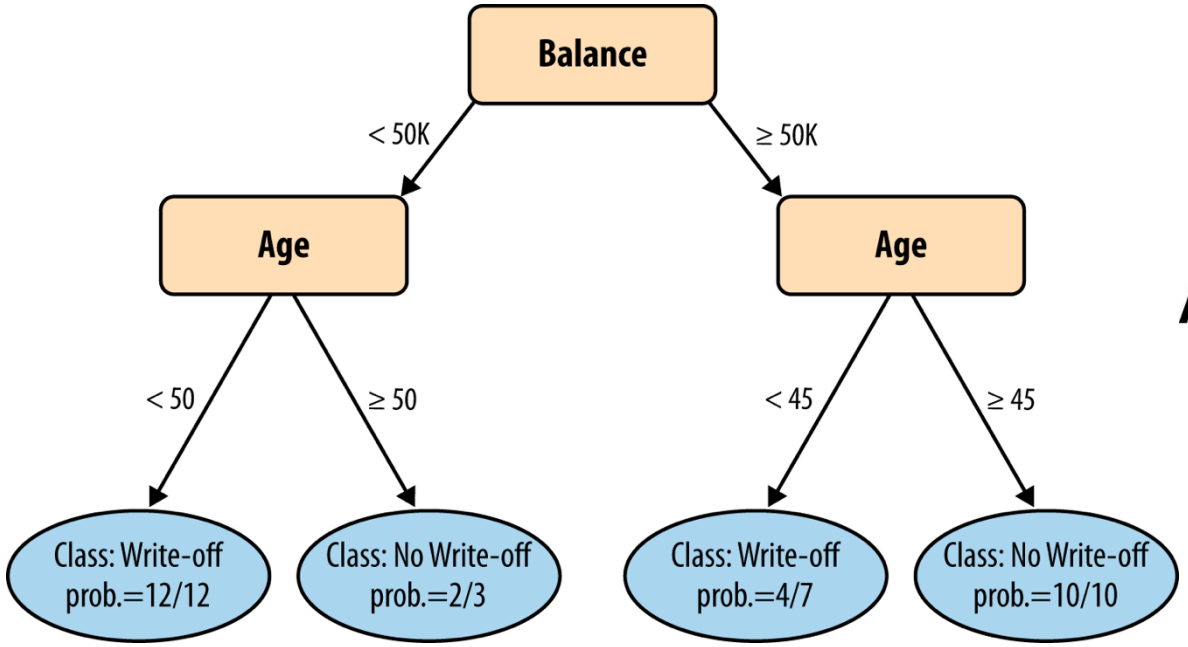
Balance
< 50K
≥ 50K
Age
Age
< 50
≥ 50
< 45
≥ 45
Class: Write-off
prob.=12/12
Class: No Write-off
prob.=2/3
Class: Write-off
prob.=4/7
Class: No Write-off
prob.=10/10

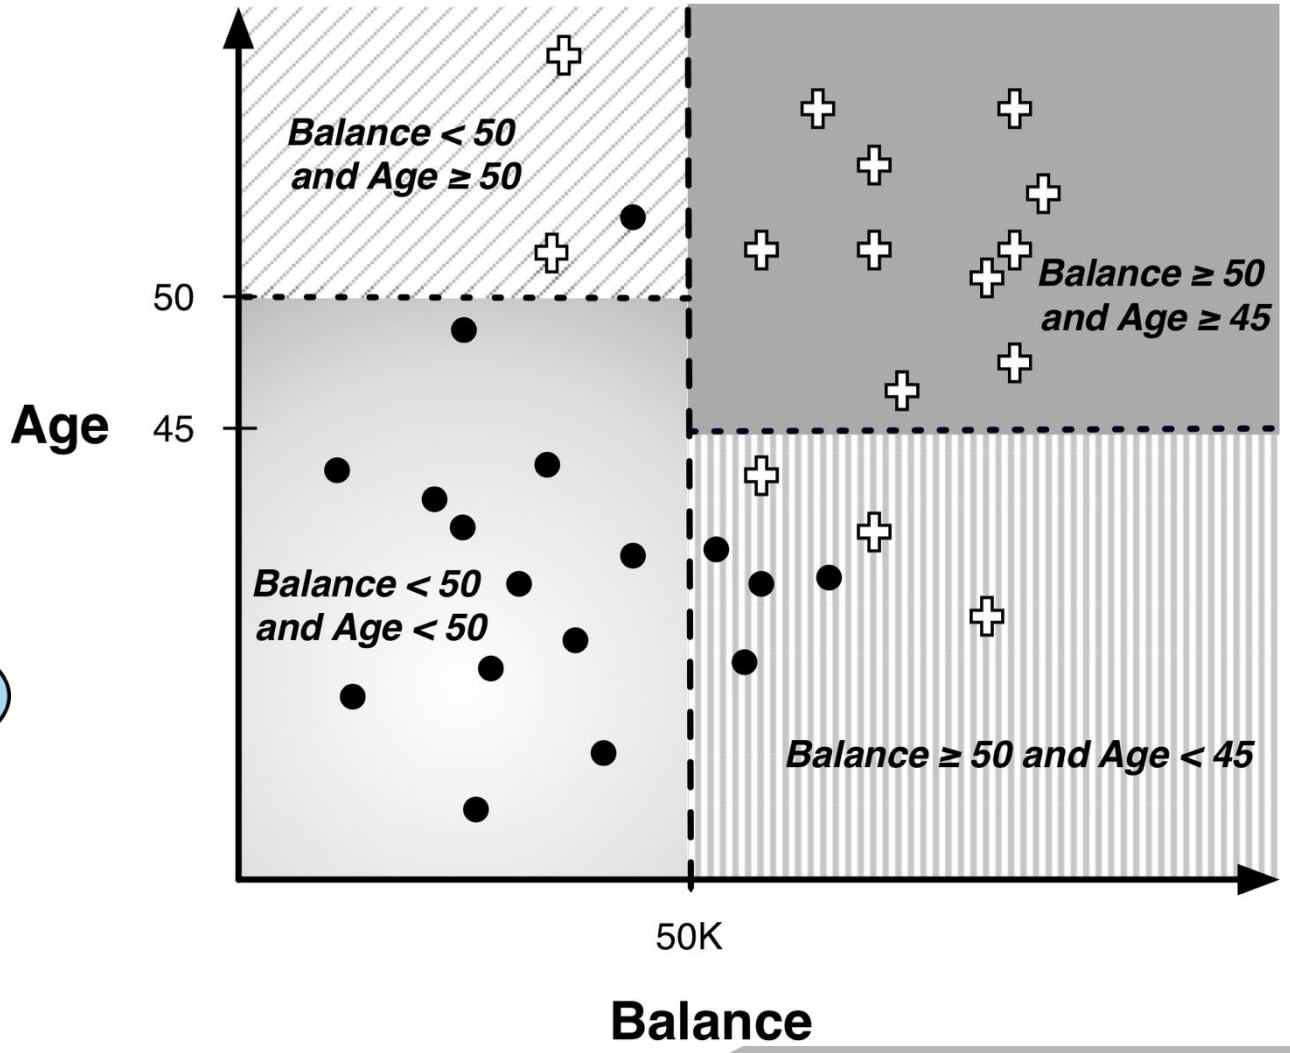
Balance < 50
and Age ≥ 50
Balance ≥ 50
and Age ≥ 45
Balance < 50
and Age < 50
Balance ≥ 50 and Age < 45
50
45
Age
50K
Balance

확률 추정

- **비즈니스 애플리케이션에서는 어떤 계층에 속하는지 보다 어느 계층에 속할 확률(예, 고객 이탈 확률, 대손 상각 활률 등)을 예측해야 하는 경우가 많음**
  - 단말노드에는 단순한 값이 아니라 세그먼트에 속할 확률이 있어야 함
  - 예를 들어, 단순히 어떤 고객이 계약 만료 후 90일 안에 서비스를 해지할지 예측하기 보다 90일 안에 서비스를 해지할 가능성이 얼마나 되는지를 추정할 필요 —> 더욱 정밀한 비지니스 의사결정을 지원할 수 있음
- **확률 추정 트리**
  - 트리의 단말노드에 있는 모든 객체에 동일한 계층 확률을 부여해도 된다면 단말노드에 있는 객체 수를 이용해 계층 확률 추정치를 계산할 수 있음
  - Frequency-based estimate of class membership probability
    - 단말노드에 n개의 긍정객체와 m개의 부정객체가 있다면 새로 이 세그먼트로 분류된 객체가 긍정계층에 속할 확률은 n/(n+m) 임
    - 그러나 세그먼트 안에 객체의 수가 상당히 적을 때에는 확률 추정이 너무 긍정적으로 나올 수 있다는 단점이 존재
    - 세그먼트에 속한 객체가 1개라면 이 세그먼트로 분류된 새로운 객체가 동일한 계층에 속할 확률이 100%라고 말할 수 있는가? —> 과적합(overfitting)

확률 추정

- **라플라스 교정법(Laplace correction)**
  - 빈도를 계산할 객체의 수가 너무 적을 때 발생되는 문제를 완화
  - 2진 분류에서 확률 추정식은 다음과 같이 수정
  - $p(c) = \frac{n+1}{n+m+2}$
  - 2개의 긍정객체, 부정객체 0 인 세그먼트의 본래 빈도 확률 추정치 1, 라플라스 교정법 적용하면 0.75
  - 20개의 긍정객체, 부정객체 0인 세그먼트의 본래 빈도 확률 추정치 1, 라플라스 교정법 적용하면 0.95에 근접

2/3, 4/5, 1/1 객체비율을 가진 세그먼트에서 객체 개수에 따른 라플라스 교정법의 효과

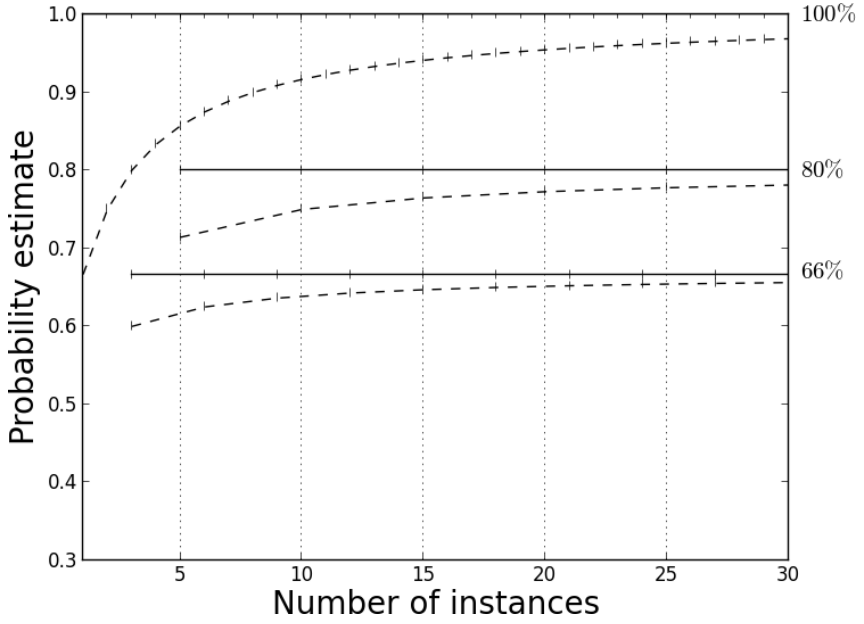

연습문제: 고객 이탈 문제

Variable	Explanation
COLLEGE	Is the customer college educated?
INCOME	Annual income
OVERAGE	Average overcharges per month
LEFTOVER	Average number of leftover minutes per month
HOUSE	Estimated value of dwelling (from census tract)
HANDSET_PRICE	Cost of phone
LONG_CALLS_PER_MONTH	Average number of long calls (15 mins or over) per month
AVERAGE_CALL_DURATION	Average duration of a call
REPORTED_SATISFACTION	Reported level of satisfaction
REPORTED_USAGE_LEVEL	Self-reported usage level
LEAVE *(Target variable)*	Did the customer stay or leave (churn)?

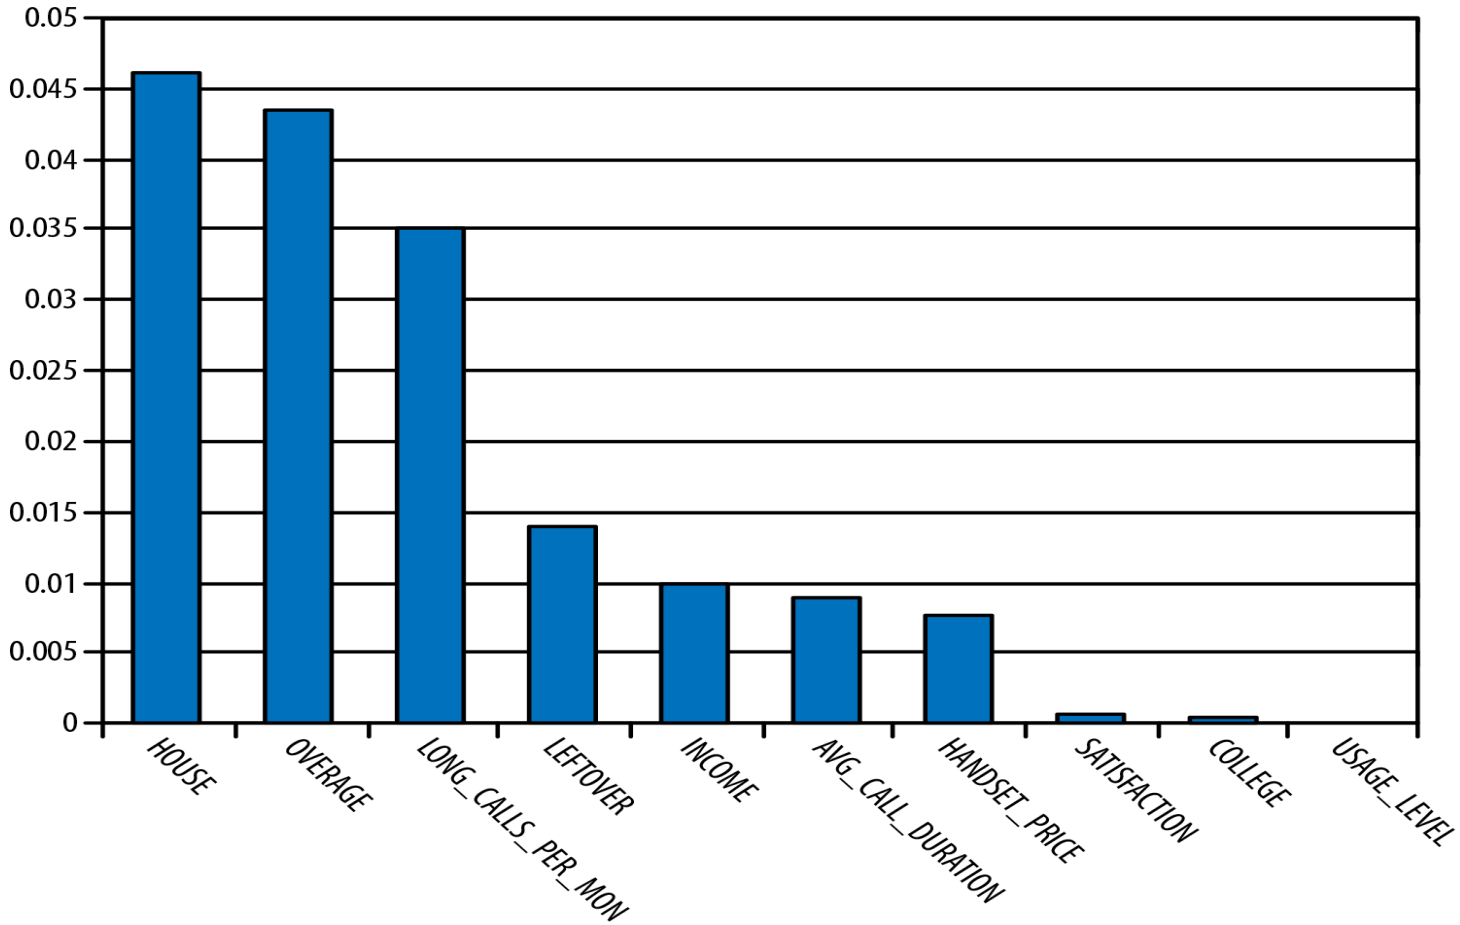

Rank	Info. gain	Attribute name
1	0.0461	HOUSE
2	0.0436	OVERAGE
3	0.0350	LONG_CALLS_PER_MON
4	0.0136	LEFTOVER
5	0.0101	INCOME
6	0.0089	AVG_CALL_DURATION
7	0.0076	HANDSET_PRICE
8	0.0003	SATISFACTION
9	0.000	COLLEGE
10	0.000	USAGE_LEVEL

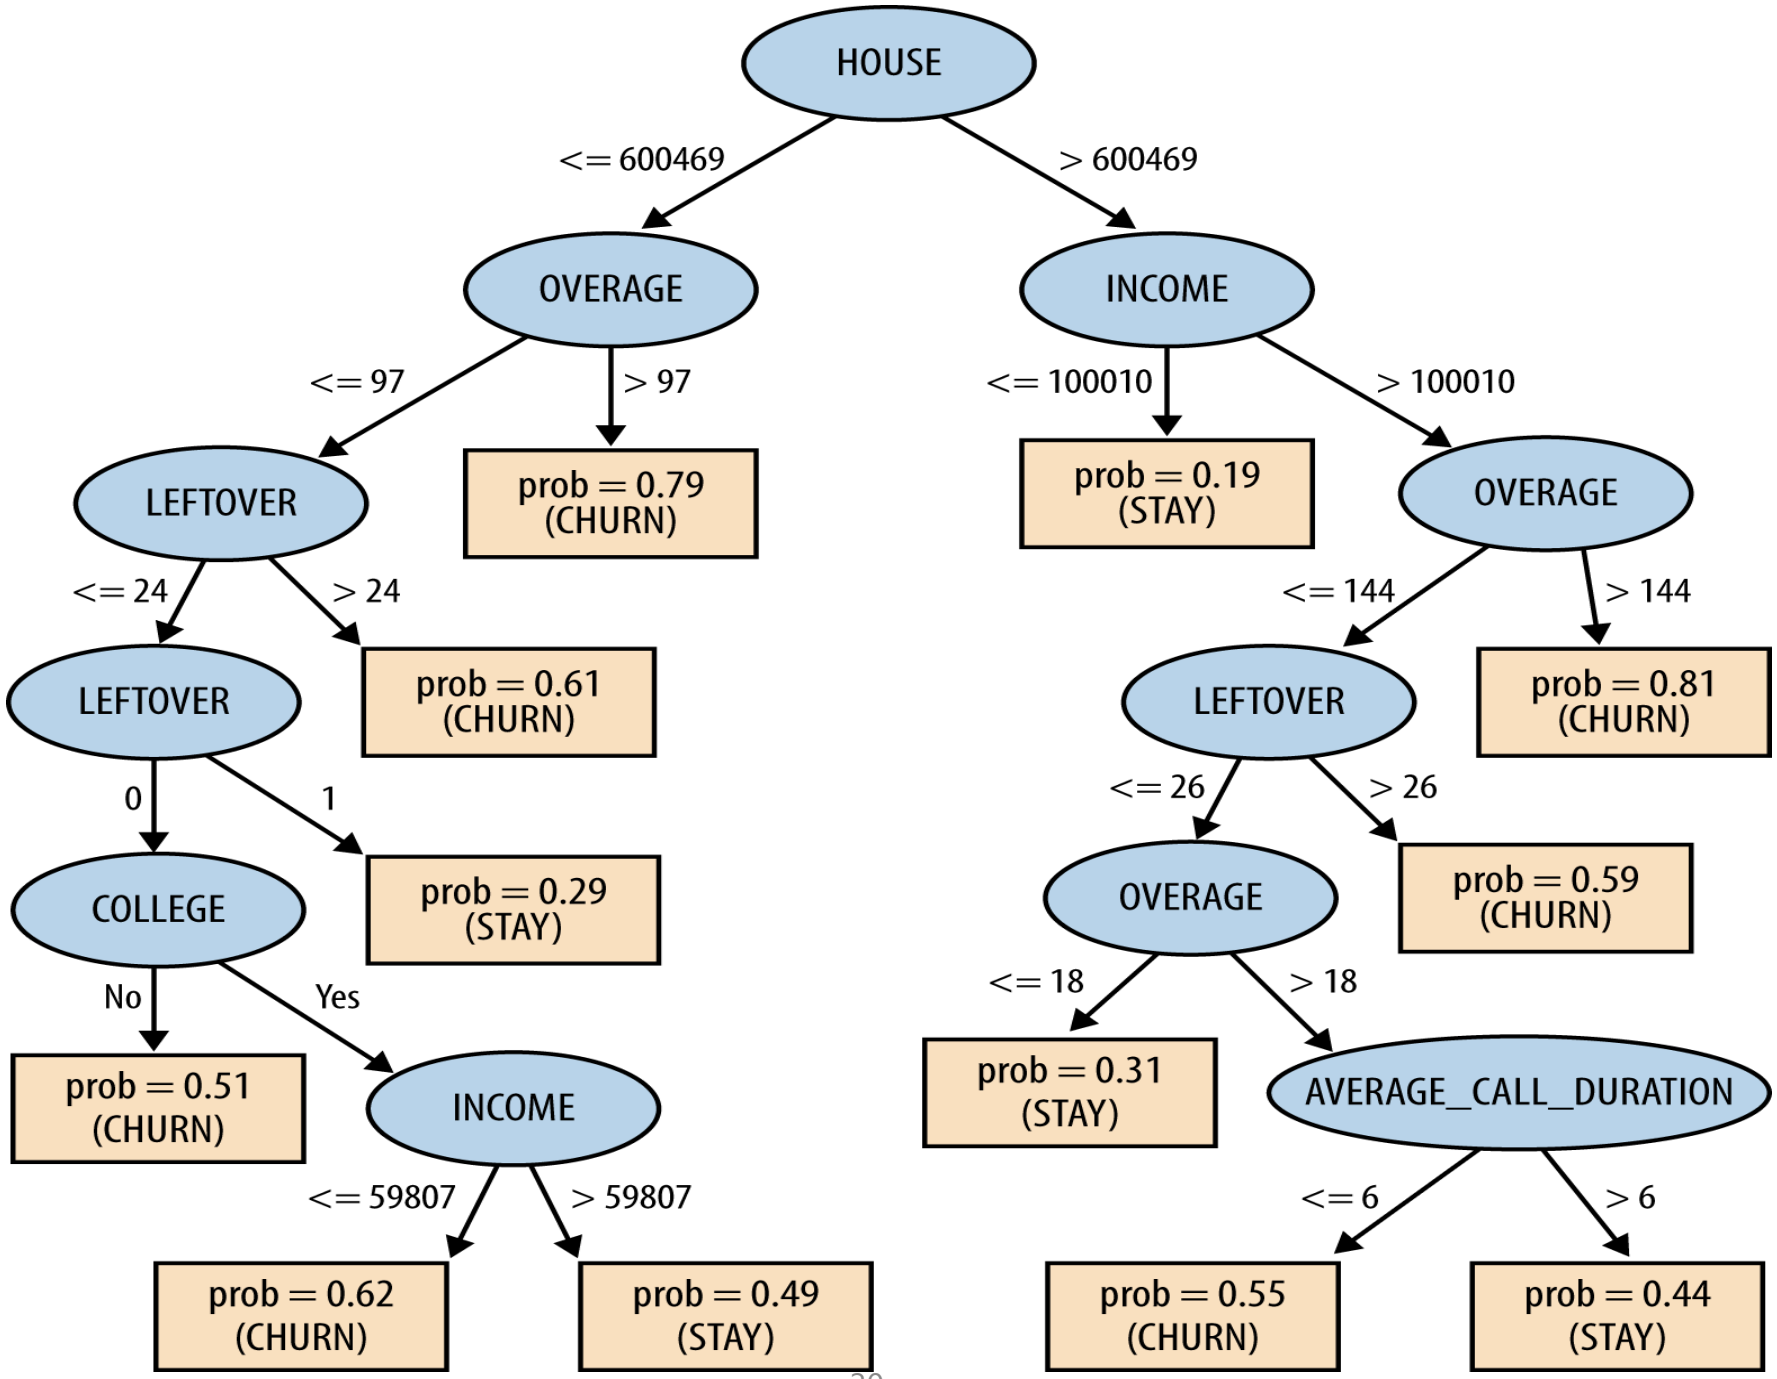
HOUSE
<= 600469
> 600469
OVERAGE
INCOME
<= 97
> 97
<= 100010
> 100010
LEFTOVER
prob = 0.79 (CHURN)
prob = 0.19 (STAY)
OVERAGE
<= 24
> 24
<= 144
> 144
LEFTOVER
prob = 0.61 (CHURN)
LEFTOVER
prob = 0.81 (CHURN)
0
1
<= 26
> 26
COLLEGE
prob = 0.29 (STAY)
OVERAGE
prob = 0.59 (CHURN)
No
Yes
<= 18
> 18
prob = 0.51 (CHURN)
INCOME
prob = 0.31 (STAY)
AVERAGE_CALL_DURATION
<= 59807
> 59807
<= 6
> 6
prob = 0.62 (CHURN)
prob = 0.49 (STAY)
prob = 0.55 (CHURN)
prob = 0.44 (STAY)

결정트리 기반 앙상블(ensemble) 모델

- **결정트리의 문제점**
  - 훈련데이터에 과적합될 가능성이 높음
  - 결국 정확도가 떨어짐
- **결정트리의 단점을 보완하기 위한 앙상블 모델***
  - 렌덤포레스트(random forest)
  - 그래디언 부스팅 방법(GBM, gradient boosting method)
  - 랜덤포레스트와 GBM은 모델을 구성하는 기본 요소로 결정트리 사용
- **랜덤포레스트**
  - 기본적으로 조금씩 다른 여러 개의 결정트리의 묶음
  - 결국, 결정트리가 너무 커지면 훈련데이터 과적합 되는 문제가 발생하기 때문에 작은 트리들을 묶어서 숲(forest)을 만드는 방법

*앙상블 모델(ensemble model) : 여러 머신러닝 모델을 연결하여 더 강력한 모델을 만드는 기법

랜덤포레스트

- 훈련을 통해서 구성해 놓은 다수의 결정트리들로부터 분류 결과를 취합하여 투표를 통해서 결론을 얻는 방법

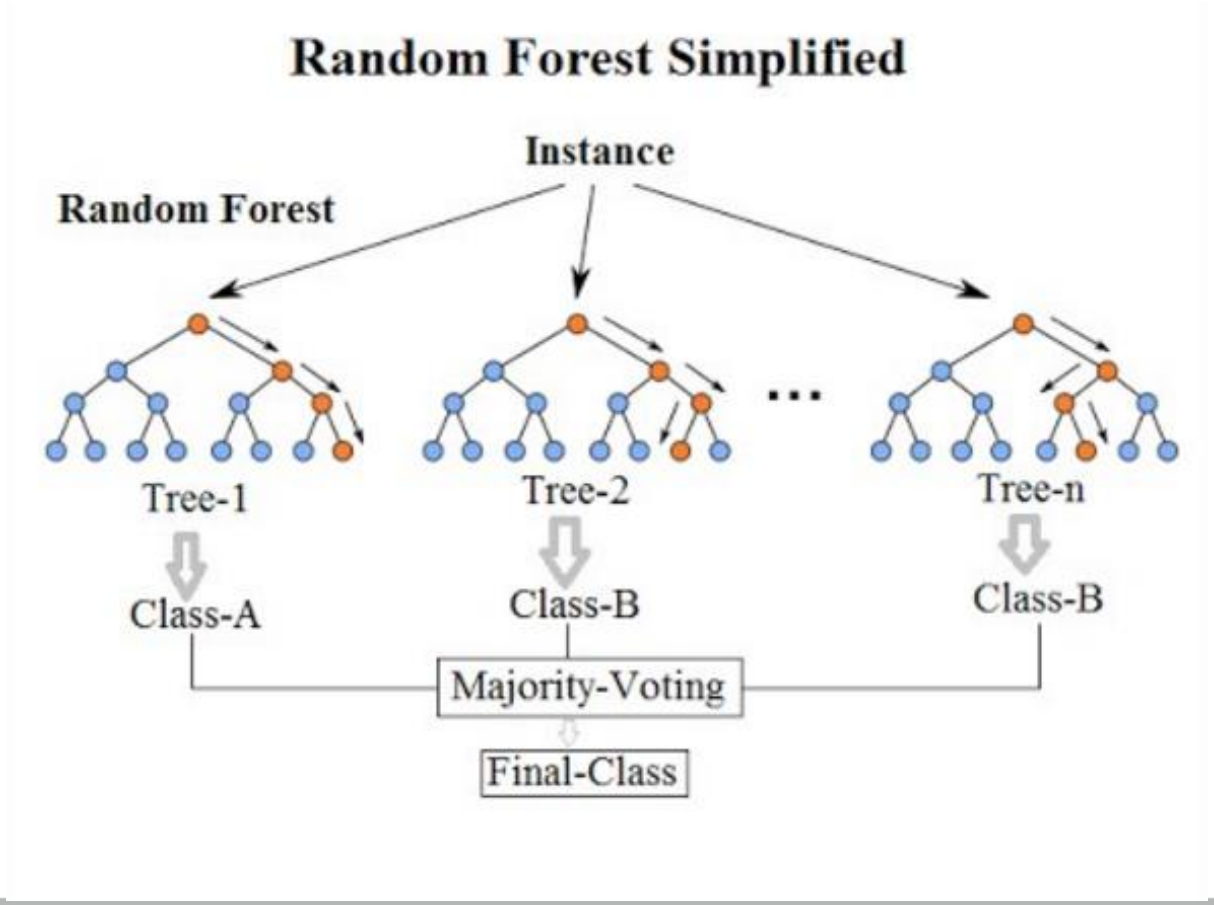

랜덤포레스트

- **배깅(bagging or bootstrap aggregating)**
  - 데이터 집합로부터 반복적으로 램덤하게 데이터들을 추출하여 다수의 결정트리를 만드는 방법
  - 예를 들어, 1000개의 데이터가 있을 때 랜덤하게 100개를 뽑아서 하나의 결정트리(약한 분류기)를 만들고 다시 100를 집어 넣고(중복 허용) 100개를 다시 뽑아 두번째 결정트리를 만드는 과정을 반복하여 원하는 수만큼의 결정트리를 만들수 있음
- **보팅(voting)**
  - 램덤 포레스트를 구성하는 다수의 결정트리에 테스트 데이터를 입력으로 넣어서 분류값들이 결정되면 이 값들을 가지고 투표를 통해서 최종 분류값을 결정하게 됨
  - 약한 분류기(weak classifier)들이 보여서 결국 강한 분류기(strong classifier)를 만들 수 있음

GBM

- 랜덤포레스트와 유사하게 다수의 결정트리를 사용하지만 가장 큰 차이점은 이전 결정트리의 오차를 보완하는 방식으로 순차적으로 트리를 만든다는 것이 가장 큰 차이점임
- 즉, 랜덤하게 결정트리를 만드는 것이 아니라 gradient 최적화를 통하여 이전 학습기*가 잘 못 예측한 데이터를 다음 단계에서 학습하여 상호 보환하는 방식
- 여러 개의 약한 학습기(weak learner)를 순차적으로 결합해 강력한 하나의 학습기(strong leaner)를 만드는 방식
- 최근 kaggle 등 다양한 데이터 분석 대회에서 상위권을 기록하며 부상한 XGBoost, LightGBM 등이 대표적인 GBM 기반 병렬화 라이브러리임
- 뛰어난 성능을 보이는 반면 학습과 추론시 많은 연산량이 요구되며 과적합되는 경향이 있어 파라미터 선정이 중요함

*GBM은 분류와 회귀에 모두 사용이 가능하기 때문에 분류기가 아니라 학습기로 부름

앙상블 모델

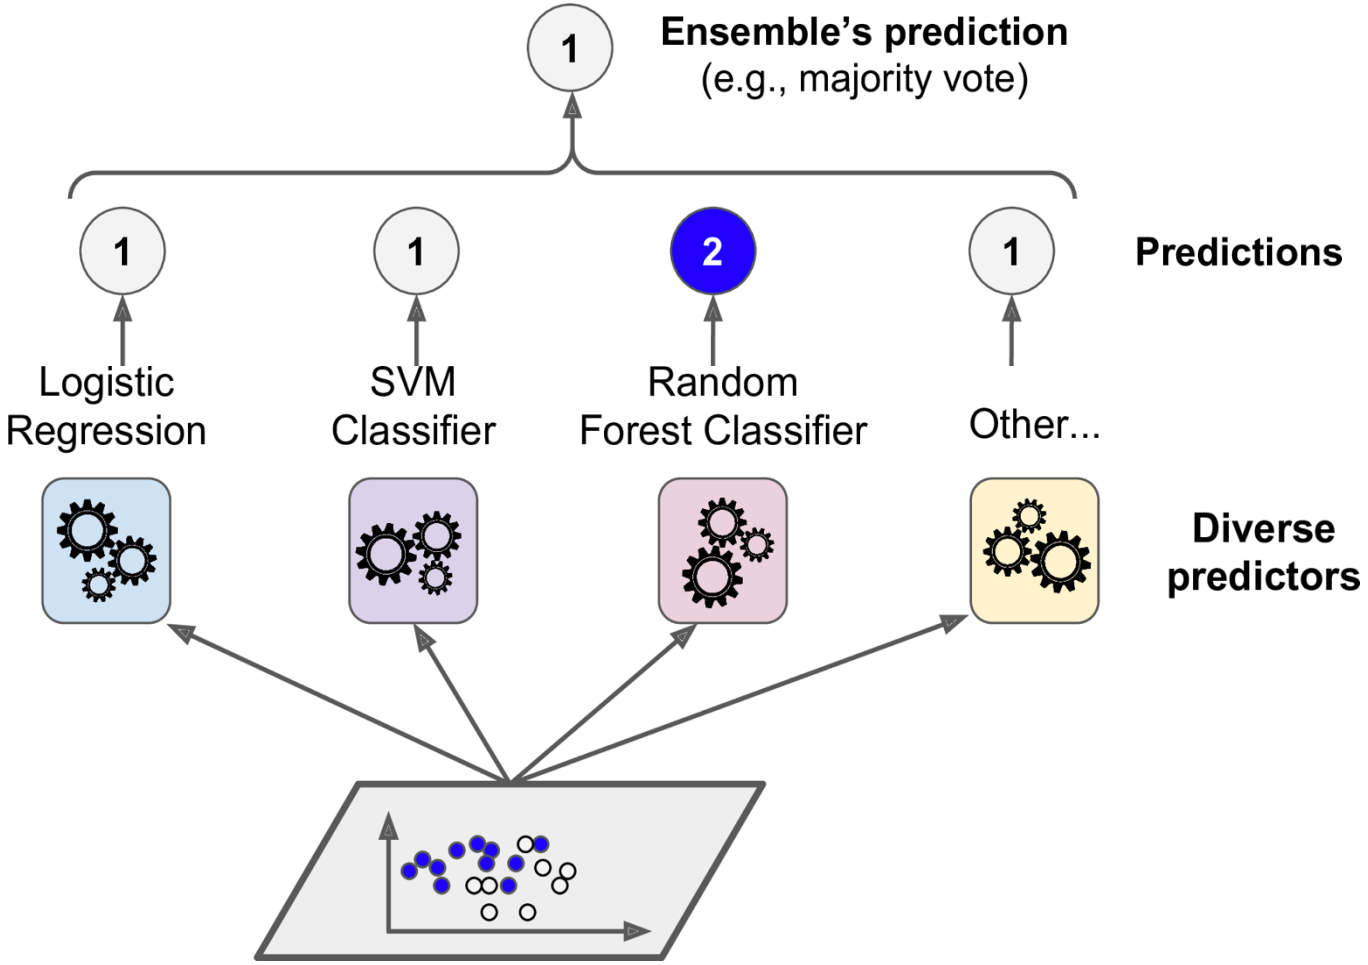
1
Ensemble's prediction
(e.g., majority vote)
1
1
2
1
Predictions
Logistic
Regression
SVM
Classifier
Random
Forest Classifier
Other...
Diverse
predictors